

# 推荐任务中知识图谱嵌入应用研究综述

田萱<sup>1,2+</sup>, 陈杭雪<sup>1,2</sup>

1. 北京林业大学 信息学院, 北京 100083

2. 国家林业草原林业智能信息处理工程技术研究中心, 北京 100083

+ 通信作者 E-mail: tianxuan@bjfu.edu.cn

**摘要:** 推荐系统旨在为用户推荐个性化内容以提升用户体验, 但目前仍面临着诸如可解释性差、冷启动问题和序列化推荐建模等挑战。近年来, 蕴含大量结构化知识和语义信息知识图谱被广泛应用于各种推荐任务中以期缓解上述问题。本文对不同推荐任务中知识图谱嵌入的创新应用进行系统性综述。首先梳理了采用知识图谱嵌入的三类常见推荐任务以及知识图谱嵌入应用的四种目的; 然后根据技术不同归纳总结出四类知识图谱嵌入方法, 包括传统嵌入方法、嵌入传播方法、异质图嵌入方法和基于图神经网络的方法; 进一步详细阐述了每类方法在不同推荐任务中的使用特点及应用策略, 评价其优点和局限性等, 并从多个方面对方法间的联系与区别进行定性和定量的分析。最后, 针对面向不同推荐任务中知识图谱嵌入应用的发展趋势提出一些看法, 从多个角度展望了该领域未来值得关注的几个发展方向。

**关键词:** 知识图谱嵌入; 推荐任务; 可解释性; 冷启动; 序列化推荐; 知识图谱嵌入应用

**文献标志码:** A      **中图分类号:** TP319

## Survey on Applications of Knowledge Graph Embedding in Recommendation Tasks

TIAN Xuan<sup>1,2+</sup>, CHEN Hangxue<sup>1,2</sup>

1. School of Information Science and Technology, Beijing Forestry University, Beijing 100083, China

2. Engineering Research Center for Forestry-oriented Intelligent Information Processing of National Forestry and Grassland Administration, Beijing 100083, China

**Abstract:** Recommendation systems are designed to recommend personalized content to improve user experience. At present, the recommendation systems still face some challenges such as poor interpretability, cold start problem and serialized recommendation modeling. Recently the knowledge graph containing a large amount of semantic and structural information has been widely used in a variety of different recommendation tasks and effectively alleviate

**基金项目:** 国家重点研发计划资助(2018YFC1603305)。

This work was supported by the National Key Research and Development Program of China (2018YFC1603305).

the above problems. This paper systematically reviews the innovative applications of knowledge graph embedding in different recommendation tasks. We first sort out three types of common recommendation tasks and four applying of the of knowledge graph embedding, including traditional embedding method, embedding propagation method, heterogeneous graph embedding method and graph neural network based method. Then, we summarize four types of knowledge graph embedding methods according to specific technologies. We further elaborate on the applying characteristics and strategies of knowledge graph embedding methods in different recommendation tasks, evaluate advantages and limitations of each method. Also, we conduct qualitative and quantitative analysis of the connections and differences between methods from multiple aspects. Finally, we put forward some views on the development trend of applying knowledge graph embedding for recommendation systems, and prospect several noteworthy development directions in the future from multiple perspectives.

**Key words:** knowledge graph embedding; recommendation tasks; explainable recommendation; cold start; serialization recommendation; application of knowledge graph embedding

推荐算法的核心目标是满足用户个性化需求提供个性化推荐。当前推荐算法通常具有较差可解释性、冷启动问题和序列化推荐模型难以建模等局限性<sup>[1,2]</sup>, 目前许多研究者尝试通过添加其他辅助信息来解决上述问题。其中, 知识图谱(knowledge graph, KG) 蕴含丰富的结构化知识和语义信息, 已经成为有效补充推荐数据的主要方式之一<sup>[3,4]</sup>。常见的知识图谱有 Freebase<sup>[5]</sup>、DBpedia<sup>[6]</sup>、YAGO<sup>[7]</sup>和 NELL<sup>[8]</sup>等。近年来随着相关技术发展迅速, 知识图谱也被广泛应用于不同的推荐应用中。

知识图谱是由实体和关系组成的多关系图, 通常用三元组来表示。虽然三元组在结构化数据表示上较为有效, 但其潜在的符号特性通常使得知识图谱较难真正融合到实际应用中<sup>[9]</sup>。为解决该问题, 知识图谱嵌入(knowledge graph embedding, KGE) 被提出, 并在推荐系统中获得大量关注<sup>[10-12]</sup>。其核心思想是将知识图谱中的实体和关系嵌入到连续空间中, 并获得相应的嵌入表示, 并用于扩充推荐系统中项目和用户语义表征<sup>[13-15]</sup>。

在已有研究中, Wang 等<sup>[16]</sup>曾系统回顾了知识图谱嵌入技术, 介绍了各种模型框架、训练过程及优缺点; Qin 等<sup>[17]</sup>对基于知识图谱的推荐系统进行了梳理, 将方法进行分类并总结了其在推荐中的应用; Zhu 等<sup>[18]</sup>将用于推荐的知识图谱方法分为基于连接、基于嵌入和基于混合三类。与以往只关注知

识图谱单独应用的研究工作相比, 本文特色主要体现在我们将知识图谱嵌入视为整个推荐过程中的上游任务, 首先总结归纳出 KGE 的四类应用目的, 然后从推荐任务的多样性角度出发全面综述了 KGE 与下游任务中不同算法的创新融合方式。

本文第 1 节介绍推荐系统中 KGE 应用在推荐任务中的研究背景, 包括推荐系统中的常见任务以及 KGE 方法的应用意义和分类。第 2 节对可解释推荐任务中 KGE 方法分析介绍。第 3 节对冷启动任务中 KGE 方法分析梳理。第 4 节对序列化推荐任务中 KGE 方法进行梳理。第 5 节从不同方面讨论推荐系统中知识图谱嵌入应用未来的研究方向和发展趋势。最后第 6 节对全文进行总结。

## 1 研究背景

### 1.1 推荐系统中常见任务

推荐系统中存在着推荐可解释性差、冷启动和用户动态偏好难以建模等经典问题。可解释推荐(explainable recommendation) 在输出推荐列表的同时生成推荐结果解释, 旨在提高推荐结果的说服力、可信度和用户满意度<sup>[19]</sup>; 面对系统中新用户或新项目交互数据稀疏性导致的冷启动问题, 近年来越来越多的研究者通过添加辅助信息缓解推荐数据的稀疏性; 不同于传统推荐系统以静态的方式建

模用户和项目间的交互<sup>[20]</sup>，序列化推荐（sequential recommendation）旨在将交互建模为动态序列进而挖掘更全面的用户偏好<sup>[21]</sup>。目前，通过嵌入 KG 中包含的结构化实体知识和丰富关系，或探索推荐产生的原因以生成更直观和有针对性的解释<sup>[22]</sup>，或增强推荐数据的表示以缓解冷启动问题，或建模动态且细粒度的用户偏好以提升序列化推荐性能<sup>[23-25]</sup>，KGE 应用逐渐成为推荐领域的研究焦点。因此本文重点分析梳理 KGE 方法在上述推荐任务中的创新应用，深入探索其与下游方法的应用策略及特征。

## 1.2 知识图谱嵌入方法应用

在充分调研近年来基于知识图谱嵌入方法的推荐相关研究之后，我们将可解释推荐、序列化推荐以及面向冷启动的推荐任务中 KGE 方法的应用目的归纳总结为以下四类：1）增强项目或项目属性的表示，利用 KG 实体和关系信息丰富推荐系统中对应数据的表示。2）增强用户和项目关联的表示，利用 KG 蕴含的丰富语义增强数据表示并通过其高阶链接探索用户和项目的潜在交互。3）丰富用户交互信息，结合用户-项目二部图和知识图谱生成协同知识图谱（collaborative knowledge graph, CKG），利用 KG 语义信息和高阶结构特征丰富用户-项目交互信息。4）增强特定领域的的数据表示，构造特定领域的知识图谱以提升推荐过程中的数据表示质量（如音乐推荐、新闻推荐等）。

事实上，KGE 在推荐过程中大都属于上游任务，探索其与下游任务中不同方法的融合方式及应用特征是本文研究的创新和焦点所在。目前不同推荐任务中 KGE 应用的下游任务方法涵盖多个领域的先进模型，如马尔可夫决策过程（markov decision process, MDP）<sup>[26]</sup>、长短期记忆神经网络（long short-term memory, LSTM）<sup>[27]</sup>和卷积神经网络（convolutional neural networks, CNN）<sup>[28]</sup>等。

不同于只关注知识图谱单独应用的已有研究工

作<sup>[16-18]</sup>，本文从 KGE 方法自身的分类及其与下游任务中方法的创新融合两个角度出发进行梳理归纳，综述了知识图谱在不同推荐任务的使用策略和应用特征。借鉴文献[18]对知识图谱方法的划分标准，我们将 KGE 方法进一步分为传统嵌入方法、嵌入传播方法、异质图嵌入和基于图神经网络四类，图 1 展示了推荐任务中不同 KGE 方法与下游应用方法的创新融合应用特征。

其中，传统嵌入方法定义评分函数学习知识图谱中实体和关系表示，可分为平移距离模型和语义匹配模型，常见方法有 TransE<sup>[29]</sup>、TransH<sup>[10]</sup>、TransR<sup>[11]</sup>和 TransD<sup>[30]</sup>；嵌入传播方法则在其基础上引入路径推理<sup>[31]</sup>建模实体间的多步关系路径，通过实体间的高阶连通性传播相邻节点语义以挖掘用户潜在兴趣，为提升推荐性能和可解释性提供了新途径<sup>[32]</sup>。此外，在一些真实场景下构建的知识图谱是模式丰富的异质图，包含多类型实体和关系，嵌入异质图有助于发现隐含交互行为以全面刻画用户特征<sup>[33]</sup>。图神经网络（graph neural networks, GNN）可以有效整合 KG 结构特征及属性特征<sup>[34]</sup>，利用其强大的信息传播能力学习项目间语义关系和用户潜在偏好，主要包括图卷积网络（graph convolutional network, GCN）<sup>[35]</sup>和图注意力网络（graph attention network, GAT）<sup>[36]</sup>两类方法。

综上所述，四类知识图谱嵌入方法在可解释推荐、序列化推荐以及面向冷启动的推荐任务中均有广泛应用，涵盖了电影、音乐、图书、电子商务、商业以及新闻等不同领域。其中，电影推荐常用数据集有 MovieLens 和 DouBanMovie；音乐推荐有 Last.FM；图书推荐包含 Douban Book、AmazonBook、Book-Crossing 和 IntentBook；电子商务推荐数据集主要来源于电商网站 Amazon；商业推荐有 Yelp 和 Dianping-Food；新闻推荐有 MIND、BingNews 和 Adressa 等数据集。鉴于上述数据集在相关综述文献中已有详细的介绍<sup>[12,17,18]</sup>，本文将不再赘述。

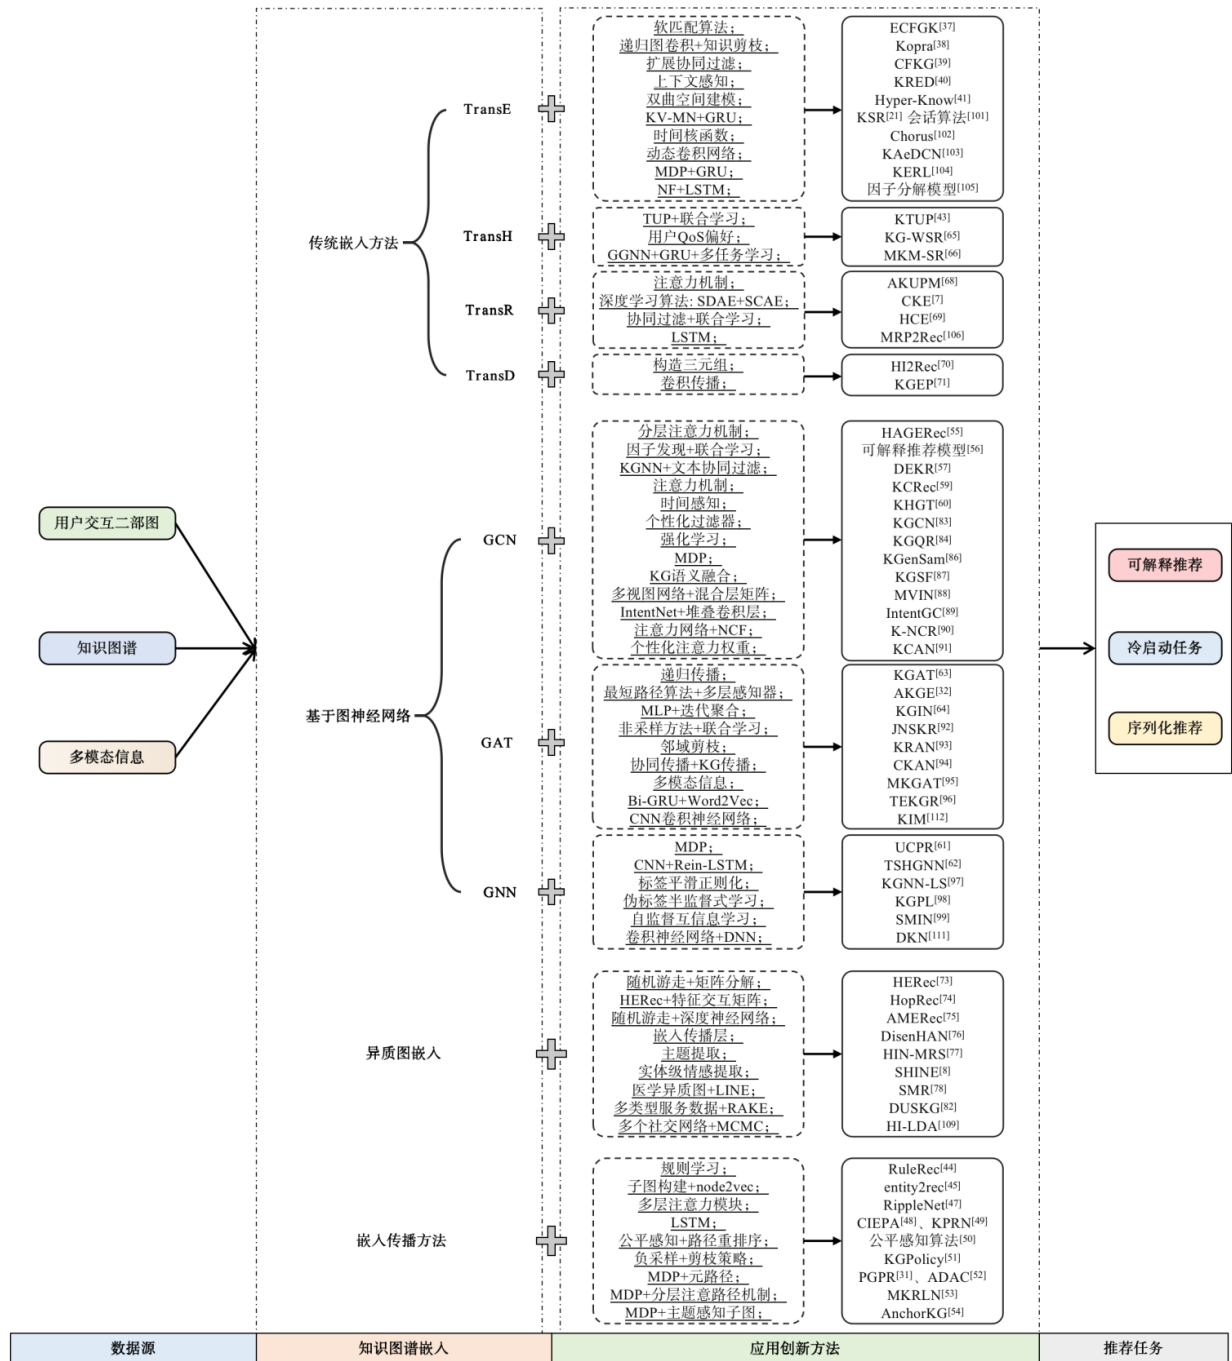


Fig.1 KGE method and application for different recommendation tasks

图1 面向不同推荐任务中的 KGE 方法及应用

## 2 可解释推荐任务

KGE 方法通过增强项目语义或建模细粒度用

户偏好有助于提升推荐可解释性, 目前常用的方法包括传统嵌入方法、嵌入传播方法和基于图神经网络的方法, 我们将其概括如表 1 所示。

Table 1 Comparison of KGE application methods for explainable recommendation tasks

表 1 面向可解释推荐任务的 KGE 应用方法对比

嵌入方法	模型框架	会议	创新应用	优点	局限性	应用场景
传统嵌入方法	EFGK <sup>[9]</sup>	Algorithms,18	TransE+软匹配算法	训练效率高,可灵活变化嵌入大小	不同数据集上的性能差距大	电子商务
	Kopra <sup>[30]</sup>	SIGIR,21	TransE+递归图卷积+剪枝	建模多样化的新闻语义和用户兴趣	忽略了新闻内容中的实体信息	新闻
	CHKG <sup>[36]</sup>	CORR,18	TransE+扩展协同过滤	从处理多类型数据,且效率高	难以建模 KG 的高阶连通性	电子商务
	KRED <sup>[36]</sup>	RecSys,20	TransE+上下文感知	强调了新闻内容中实体的重要性	计算成本较高训练时间较长	新闻
	Hyper-Know <sup>[41]</sup>	AAAI,21	TransE+双曲空间建模	参数少,计算量小,效率高	不包含用户信息,不够全面	音乐,图书
	KTUP <sup>[41]</sup>	WWW,19	TransH+TUP+联合学习	充分考虑了 KG 的不完全性	存在冷启动问题	电影,图书
	RuleRec <sup>[41]</sup>	WWW,19	嵌入传播+规则学习	考虑项目间关系类型,泛化能力强	增加规则数量会降低推荐精度	电子商务
	entity2rec <sup>[41]</sup>	ESWA,20	嵌入传播+node2rec	可以生成推荐结果的丰富解释	参数较多聚合函数性能下降	电影,图书,新闻,
	RippleNet <sup>[41]</sup>	CIKM,18	嵌入传播+多层注意力	有效挖掘用户潜在兴趣,性能显著	大规模迭代运算提高计算成本	
	CLEPA <sup>[41]</sup>	KBS,21	嵌入传播+LSTM	计算开销小,且模型扩展性较好	高度依赖于丰富用户评分数据	
嵌入传播方法	KPRN <sup>[40]</sup>	AAAI,19	嵌入传播+LSTM	显式地探索用户项目间复杂关系	训练时间长且模型复杂度高	电影,音乐
	公平性算法 <sup>[40]</sup>	SIGIR,20	嵌入传播+公平感知	有效降低了推荐不公平性	缺乏对长路径的学习	电子商务
	KGPolicy <sup>[39]</sup>	WWW,20	嵌入传播+负采样	显著降低了探索空间小、复杂度低	在交互稀疏场景下的性能较差	图书,音乐
	PGPR <sup>[40]</sup>	SIGIR,19	嵌入传播+MDP	结合 RL 方法提供可靠、多样化的解释,且模型稳定性高	推理过程中易产生噪声,复杂度较高易受寻径策略的影响	电子商务
	ADAC <sup>[39]</sup>	SIGIR,20	嵌入传播+MDP	具有较好的可解释性和收敛性	忽略了路径长度对推荐的影响	
	MKRLN <sup>[43]</sup>	KBS,21	嵌入传播+MDP+分层路径	有效过滤冗余信息减小动作空间,可以从多个角度提供推荐解释	实体数量的大幅度降低对推荐性能影响较大	
	AnchorKG <sup>[44]</sup>	KDD,21	嵌入传播+MDP	模型可扩展性强,适用于大规模 KG 的实时新闻推荐服务	目前仅适用于新闻推荐场景	新闻
	HAGERec <sup>[38]</sup>	KBS,20	GCN+分层注意力机制	可以更充分地挖掘用户潜在偏好	内存、训练难度和时间开销大	电影,图书,音乐
	可解释模型 <sup>[46]</sup>	CIKM,20	GCN+因子联合学习	有效挖掘数据不同方面的特征	忽略了对关系类型的考虑,且时间复杂度和内存成本较高	
	DEKR <sup>[47]</sup>	SIGIR,21	GCN+文本协同过滤	融合了与实体相关的文本描述信息	仅适用于机器学习领域的推荐	
基于图神经网络	KCRec <sup>[49]</sup>	KBS,21	GCN+注意力机制	有效捕获用户特征和文本重要性	模型参数较多,计算量大	图书,音乐
	KHGT <sup>[49]</sup>	AAAI,21	GCN+时间感知	引入时间信息建模动态的用户偏好	内存需求和计算成本较高	电影,零售
	UCPR <sup>[60]</sup>	SIGIR,21	GNN+MDP	实现基于用户需求组合的复杂推理,具有较快的收敛速度	仅考虑和购买历史有关联的项目,对性能有较大影响	电影,图书,电子商务
	TSHGNN <sup>[61]</sup>	FGCS,21	GNN+CNN+Rein-LSTM	根据新闻内容及时间特征充分挖掘深度新闻特征	LSTM 模型设计复杂,且嵌入维数对性能影响较大	新闻
	KGAT <sup>[63]</sup>	KDD,19	GAT+递归传播	有效增强了非活跃用户的表示	训练过程较为繁琐	电影,音乐,图书
	AKGE <sup>[49]</sup>	CORR,19	GAT+最短路径算法+MLP	充分挖掘 KG 语义和拓扑信息	复杂度较高且易产生过拟合问题	电影,音乐
	KGin <sup>[64]</sup>	WWW,21	GAT+迭代聚合	全面刻画用户与项目间的关系并保留了路径的整体语义	挖掘路径多跳关系大大增加了模型复杂度	图书,音乐,电子商务

## 2.1 传统嵌入方法

TransE 作为最具代表性的平移距离模型, 经常被用于推荐系统中的知识图谱嵌入以提升推荐可解释性。Ai 等<sup>[37]</sup>提出基于知识图谱的协同过滤架构 (explainable collaborative filtering over knowledge graph, ECFKG), 采用 TransE 建模多类型用户行为和项目属性并将协同关系编码为关系图结构, 在其基础上延伸协同过滤算法 (collaborative filtering, CF) 学习实体表示以挖掘潜在用户偏好。进一步设计软匹配算法寻找用户到项目的解释路径, 结合广度优先搜索和软匹配公式计算路径概率得到最佳路径以生成推荐的自然语言解释。Tian 等<sup>[38]</sup>联合知识剪枝和循环图卷积设计推荐算法 (knowledge pruning based recurrent graph convolutional network, Kopro), 采用 TransE 嵌入用户点击历史新闻标题和摘要中包含的重要实体, 并设计循环图卷积网络 (recurrent graph convolution, RGC) 聚合实体上下文信息构建用户兴趣图。RGC 通过知识剪枝策略识别 KG 中相关性高的实体进一步丰富和修正用户兴趣图, 从而推导出用户的长期和短期偏好表示, 更细粒度地提升了推荐的因果解释。Zhang 等<sup>[39]</sup>提出基于 KG 的协同过滤算法 (collaborative filtering with knowledge graph, CFKG), 定义多类型的实体和关系描述用户交互中的项目属性和异质关系并采用 TransE 将其嵌入到连续向量空间中, 进一步扩展协同过滤学习嵌入表示以挖掘潜在的用户偏好, 有效提升了推荐结果的可解释性。

此外, 还有研究者利用 TransE 增强新闻文档表示和双曲空间建模。Liu 等<sup>[40]</sup>提出知识感知的新闻文档表示增强模型 (knowledge-aware representation enhancement model for news documents, KRED), 如图 2 所示。KRED 首先采用 TransE 嵌入知识图谱并使用图神经网络聚合实体邻域信息, 然后设计上下文嵌入层来标注实体的类别、位置和频率等信息, 最后基于注意力机制聚合得到的信息获得增强

后的新闻文档表示。KRED 从多角度增强新闻文档的表示, 同时为提升推荐可解释性提供了新思路。Ma 等<sup>[41]</sup>提出在双曲空间中建模 KG 的方法 Hyper-Know (knowledge-enhanced recommendation model in the hyperbolic space), 采用 TransE 将知识图谱映射到双曲空间 Poincaré Ball<sup>[42]</sup>中建模实体之间的关系, 并设计双曲注意力网络带权聚合实体邻域信息, 通过衡量相邻实体的相对重要性增强用户偏好理解以提升推荐可解释性。

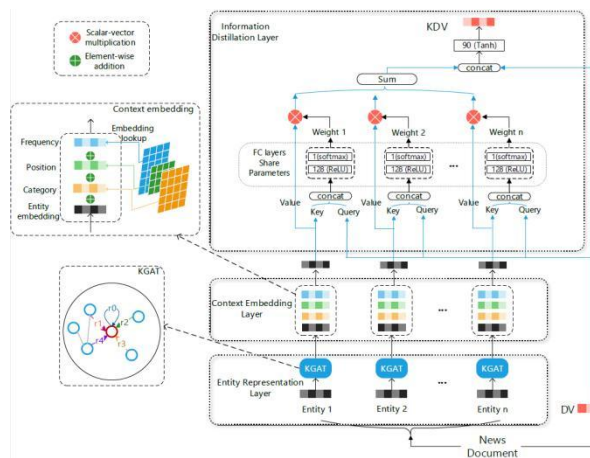


Fig.2 Three key layers of the KRED model

图 2 KRED 模型的两个关键层

也有研究者采用 TransH 实现可解释推荐任务中的知识图谱嵌入, 避免了 TransE 建模一对多和多对多等复杂关系时性能较差的局限性。Cao 等<sup>[43]</sup>提出知识增强的用户偏好模型 (knowledge-enhanced translation-based user preference model, KTUP), 由基于 TransH 的知识图谱嵌入模块和基于翻译的用户偏好模型组成, 利用 KG 丰富用户偏好和项目表示, 并通过联合学习挖掘更细粒度的用户偏好以提升推荐可解释性。

## 2.2 嵌入传播方法

知识图谱中的路径信息蕴含着实体间的高阶链接语义, 与传统嵌入方法相结合可形成嵌入传播方



法,有助于挖掘细粒度的用户偏好以提升推荐可解释性。Ma 等<sup>[44]</sup>提出 RuleRec (jointly learning explainable rules for recommendation), 基于 KG 实体间路径的链接关系抽取规则表示并推导出项目对间的规则集和规则权重,进一步结合用户交互历史生成推荐列表。RuleRec 基于规则集更好地理解用户偏好,有效提升了推荐可解释性。Palumbo 等<sup>[45]</sup>提出 entity2rec 模型,采用随机游走策略构建多个以项目属性为中心的 KG 子图,使用 node2vec<sup>[46]</sup>学习其嵌入表示,通过加权属性的多个相关性得分为推荐生成直观的解释。Wang 等<sup>[47]</sup>提出了一种融合 KG 嵌入和路径挖掘的方法 RippleNet,如图 3 所

示。RippleNet 首先获得与用户点击历史中项目相对应的 KG 多跳实体集,然后沿着 KG 高阶链接扩展实体以捕获用户潜在兴趣偏好,为增强推荐可解释性提供了新观点。基于 RippleNet 偏好传播的理念, Lin 等<sup>[48]</sup>提出一种结合项目嵌入和路径推理的方法 (combine item embedding and path attention, CIEPA), 基于 KG 高阶链接传播实体嵌入,并在传播过程中结合项目嵌入和路径注意力权重捕获细粒度的用户偏好,使用 LSTM 预测用户对项目的潜在兴趣。CIEPA 根据不同路径的重要性程度推断用户交互原因,为推荐结果提供了可靠的解释,并有效提升了计算性能和推荐精度。

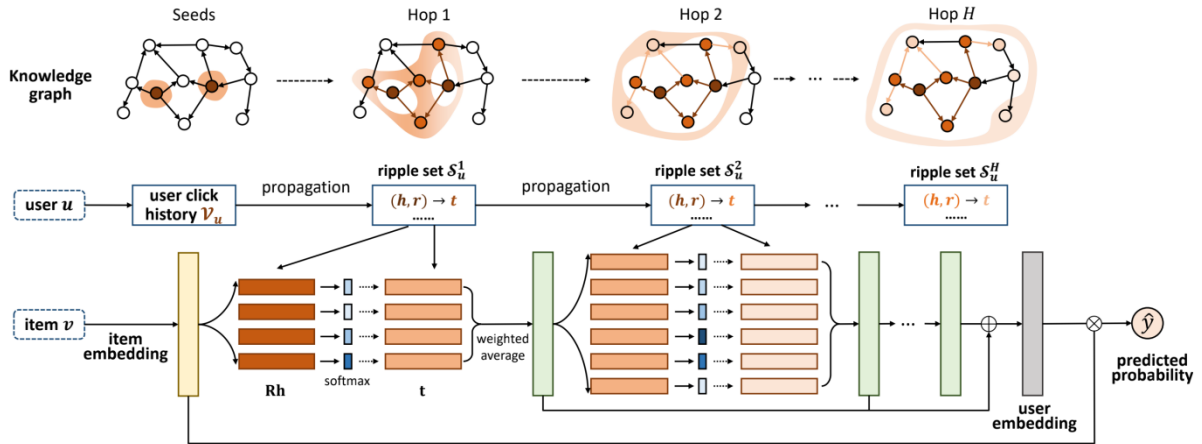


Fig.3 The overall framework of the RippleNet

图 3 RippleNet 模型总体框架

针对 RippleNet 传播过程中大规模迭代运算产生的高计算成本问题, Wang 等<sup>[49]</sup>则优化传播策略提出知识感知路径递归网络 (knowledge-aware path recurrent network, KPRN)。基于 KG 生成用户-项目对的路径表示,采用 LSTM 生成路径的语义表示并根据其重要性赋予权重,在细粒度上提升了推荐可解释性。考虑到可解释推荐中普遍存在的推荐不公平现象, Fu 等<sup>[50]</sup>提出一种公平性感知算法,利用 KG 实体间的高阶链接丰富用户历史交互,设计公平性感知排序框架学习用户到项目的多个路径表

示,通过对其进行重排序获得高质量的可解释推荐列表。模型在保证解释多样性的同时有效提升了推荐公平性。不同于以往利用 KG 建立预测模型的研究, Wang 等<sup>[51]</sup>创新性地提出基于 KG 的网络结构 (knowledge graph policy network, KGPolicy) 探索可解释推荐中的高质量负样本,设计邻居注意力模块和剪枝策略联合学习 KG 嵌入,利用 KG 实体间的链接关系探索负样本进而更准确地训练模型,提升了推荐结果的可解释性。

为了更高效挖掘 KG 高阶语义,研究者们提出

基于强化学习设计路径推理策略以提升推荐可解释性。Xian 等<sup>[31]</sup>提出基于 KGE 的策略导向路径推理方法 (policy-guided path reasoning, PGPR), 通过与 KG 环境交互探索用户到潜在感兴趣项目的最优路径推理策略, 模型架构如图 4 所示。PGPR 创

新在于将推荐问题形式化为知识图谱上的 MDP 过程, 并设计了奖励机制、用户动作修剪策略和多跳评分函数挖掘推荐候选项目及路径。PGPR 首次采用基于 KG 的强化学习方法实现可解释推荐任务中的路径推理, 多个数据集上的指标均有显著改进。

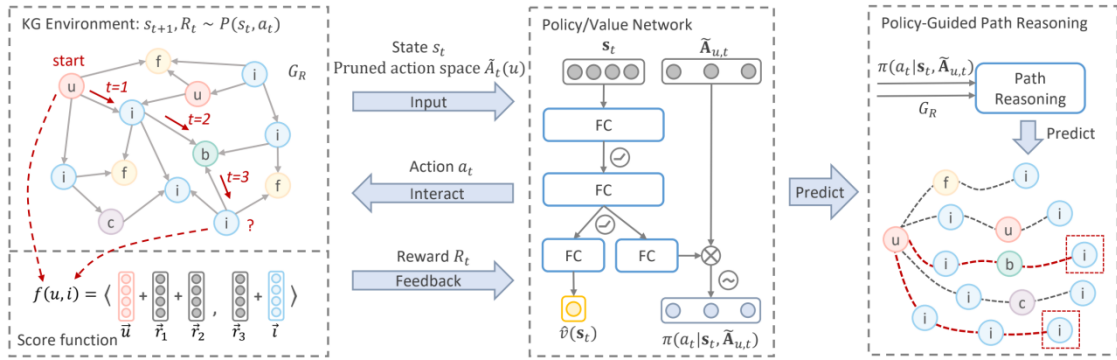


Fig.4 Pipeline of the Policy-Guided Path Reasoning method for recommendation

图 4 PGPR 模型实现推荐的传递途径

基于 PGPR 将推荐过程形式为 MDP 的理念, Zhao 等<sup>[52]</sup>基于 KGE 提出路径推理框架 ADAC (adversarial actor-critic) 用于提升推荐可解释性, 利用抽取得到的元路径自动识别可解释的推理路径, 并联合用户历史偏好优化寻径策略, 其性能相比 PGPR 有进一步提升。Tao 等<sup>[53]</sup>提出多模态知识感知的强化学习网络 (multi-modal knowledge-aware reinforcement learning network, MKRLN), 利用多模态 KG 中包含的结构和视觉信息生成推荐的路径表示, 现在在真实场景中进行可解释的视觉推理和知识推理。相比于 KGPolicy 和 PGPR 采用动作修剪策略以人为方式减少动作空间, MKRLN 设计分层注意路径机制过滤无关项目, 具有更高的效率和精度。Liu 等<sup>[54]</sup>提出一种基于 KG 的新闻推荐推理范式 AnchorKG (anchor knowledge graph), 基于知识图谱为每篇新闻文章生成一个包含其关键实体和关系的主题感知子图。其核心在于利用强化学习技术 MDP 训练子图的生成过程, 进而根据两个子图中的重叠实体和关系构建新闻文章之间可解

释的推理路径, 有效提高了新闻文档表示质量和推荐效率。

## 2.3 基于图神经网络

随着深度学习技术的发展, 图神经网络被越来越多应用在基于知识图谱的可解释推荐中。Yang 等<sup>[55]</sup>提出图卷积网络模型 (hierarchical attention graph convolutional network incorporating knowledge graph for explainable recommendation, HAGERec), 基于 GCN 设计双向实体传播策略学习 KG 高阶语义, 通过分层注意力机制准确挖掘用户潜在偏好提升推荐可解释性, 不同数据集上的实验结果相比于 RippleNet 等基线都有显著改进。Liu 等<sup>[56]</sup>提出联合因子发现和嵌入学习的可解释推荐模型, 梳理出嵌入表示的层次因子并融入到 GCN 中, 通过学习用户和项目在不同层次上的特征表示增强推荐可解释性。Cao 等<sup>[57]</sup>则基于 GCN 和知识图谱提出一种描述增强的推荐方法 (description enhanced knowledge graph recommendation, DEKR), 采用 KGNN



(knowledge graph neural network)<sup>[58]</sup>聚合实体的高阶邻域信息并结合文本协同过滤 (text-based collaborative filtering, TextCF) 增强实体的文本语义, 利用文本描述为推荐提供了可靠的解释。Zhang 等<sup>[59]</sup>提出知识感知的图卷积网络 (knowledge-aware representation graph convolutional network for recommendation, KCRec), 根据 KG 中各种关系的不同重要性聚合并传播用户特征和项目属性, 通过准确建模用户的高阶兴趣提升了推荐结果的可解释性。Xia 等<sup>[60]</sup>则基于 KG 提出分层图转换网络 (knowledge-enhanced hierarchical graph transformer network, KHGT), 基于 GCN 捕获 KG 中不同类型交互的高阶语义, 在其基础上引入时间感知的上下文信息挖掘动态依赖关系, 有助于理解用户交互的原因。

Tai 等<sup>[61]</sup>基于 GNN 提出以用户为中心的路径推理网络 (user-centric path reasoning network, UCPR), 引入 MDP 建模用户的动态需求指导 KG 路径推理, 提升推荐性能的同时为用户提供了多样化的推荐解释。Jia 等<sup>[62]</sup>提出一种时间感知的异质图神经网络模型 (temporal sensitive heterogeneous graph neural network, TSHGNN)。采用多通道卷

积神经网络从新闻实体、实体类型和活动时间中提取新闻特征, 结合 Rein-LSTM 捕获用户点击行为的序列特征, 并使用 GNN 编码用户和新闻的异质信息生成用户和候选新闻的特征表示。TSHGNN 从时间和空间两个维度建模用户和新闻的表示, 显著提升了推荐可解释性。

事实上, 知识图谱中的不同节点具有不同重要性, 因此有研究采用 GAT 学习知识图谱嵌入表示, 通过为节点分配不同权重提升推荐可解释性。Wang 等<sup>[63]</sup>提出知识图谱注意力网络 (knowledge graph attention network, KGAT), 如图 5 所示。KGAT 通过堆叠传播层递归传播节点的高阶邻域信息, 并利用 GAT 学习传播过程中邻居的权值以探索不同高阶连通的重要性。KGAT 以端到端的方式显式地建模 CKG 高阶关系, 为可解释推荐提供了新思路。而 KGAT 在整个知识图谱上传播信息, 容易引入噪音, Sha 等<sup>[32]</sup>则提出基于注意力机制的知识图谱嵌入模型 (attentive knowledge graph embedding, AKGE)。AKGE 首先构建用户和项目的高阶子图并基于 GAT 设计注意力图神经网络学习子图嵌入, 通过关系感知传播策略充分探索 KG 高阶语义, 模型的推荐效率和精度相比于 KGAT 有显著提升。

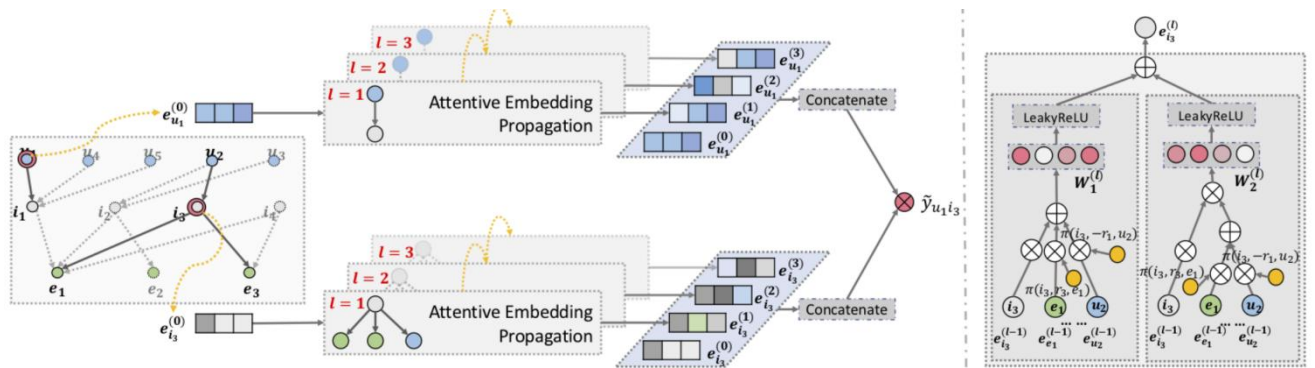


Fig.5 Illustration of the KGAT model

图 5 KGAT 模型架构图

Wang 等<sup>[64]</sup>提出基于知识图谱的意图网络 (knowledge graph-based intent network, KGIN), 将用户交互行为建模为用户意向图, 通过挖掘交互产生的原因提高推荐可解释性。实现过程中, KGIN 利用注意力机制带权聚合 KG 实体和用户多个意图表示分别获得项目和用户的嵌入表示, 通过建模不同类型关系的权重信息更细粒度地理解用户行为, 在提升推荐性能的同时为推荐结果提供了可靠解释。

## 2.4 小结

进一步对面向可解释推荐任务的 KGE 应用方法进行归纳分析, 可得到如图 6 所示的方法关联图。

其中, CIEPA 和 RuleRec 的推荐性能较 RippleNet 有显著改进, CIEPA 通过优化路径权值降低了 RippleNet 的计算开销, DoubanBook 数据集上的 ACC 值提高了 3.93%, RuleRec 在 Amazon 数据集上的 Recall 值较 RippleNet 提升高达 25.9%; PGPR 引入强化学习方法 MDP 进一步解决了 RuleRec 仅适用于关系类型较少场景的局限性; ADAC 和 UCPR 分别通过优化寻径策略和构建路径推理网络有效降低了时间复杂度, 相比 PGPR 具有更快的推荐效率和收敛速度, ADAC 在 Amazon 不同数据集上的 Precision 值较 PGPR 提升达 6.6%-14.6%, UCPR 在 MovieLens 和 Amazon Book 数据集上的 Recall

值分别提升 36.9% 和 73%。

KGAT 通过细化注意机制具有比 RippleNet 更优越的高阶建模能力, 在 Yelp2018、Last.FM 和 Amazon-Book 数据集上的 Recall 值分别提升 7.2%、9.9% 和 11.5%; AKGE 克服了 KGAT 信息更新过程中易引入噪音的局限性, 在三个数据集上的 NDCG 值分别提升 8.07%、5.72% 和 12.15%。Hyper-Know 解决了 KGAT 难以建模实体层次结构的不足, 运行速度提升高达 10 倍; KGPolicy 提升模型表达能力的同时有效降低了 KGAT 的时间复杂度; KHGT 融合时间信息更充分地挖掘用户动态偏好, 相比于 KGAT 在 Yelp 和 MovieLens 数据集上的 NDCG 值分别提升 11% 和 16.1%。

MKRLN、DEKR、KGIN、CFKG、ECFKG 和 KPRN 从不同角度建模用户与项目间的复杂关系。其中, MKRLN 引入多模态信息提升了推荐精度, 在电影和图书数据集上的 Precision 值相比 CKE 分别提升了 8.27% 和 78%; KPRN 在音乐数据集上的 NDCG 值相比 CKE 提升 5%-23%; KGIN 通过构建意向图更准确地探索用户行为的产生原因, Amazon-Book 和 Last.FM 数据集上的 Recall 值相较于 CKE 分别提升 25.7% 和 33.6%; CFKG 在 Amazon 数据集上的 Precision 值提升 23.2%-42.9%。KTUP 采用 TransH 替代 TransE 学习用户和项目间的复杂



Table 2 Comparison of KGE application methods for cold start task

表 2 面向冷启动任务的 KGE 应用方法对比

嵌入方法	模型框架	会议	创新应用	优点	局限性	应用场景
传统嵌入方法	KG-WSR <sup>[68]</sup>	Symmetry,19	TransH+用户 QoS 偏好	数据密度对推荐性能影响小	计算量大、运行时间长	Web 服务
	MKM-SR <sup>[69]</sup>	SIGIR,20	TransH+CGNN+GRU	生成更细粒度的会话和用户偏好	收敛性差,且模型复杂度较高	音乐、电商
	AKUPM <sup>[68]</sup>	KDD,19	TransR+注意力机制	降低了对无实体对推荐的影响	忽略了对输入长度可变的考虑	电影、图书
	CKE <sup>[71]</sup>	KDD,16	TransR+深度学习方法	统一联合结构、文本和图像等信息	仅探索了项目的一阶实体语义	
	HCE <sup>[69]</sup>	PAKDD,18	TransR+CF+联合学习	能够增强 KG 没有包含的项目语义	难以捕获实体间的高阶交互	GitHub
	KGEIP <sup>[71]</sup>	SOC,20	TransD+卷积传播	可以充分捕获 KG 高阶语义	计算开销大、仅用于 App 推荐	App 推荐
	MKR <sup>[72]</sup>	WWW,19	语义匹配+交叉压缩单元	利用多任务学习框架挖掘实体交互	数据过于稠密时性能下降明显	电影、图书、音乐、新闻
	HERec <sup>[73]</sup>	TKDE,19	随机游走+矩阵分解	可以高效地从 KG 中提取并利用信息	扩展性差且复杂性受路径影响	电影、图书、商业
	HopRec <sup>[74]</sup>	ESWA,21	HERec+特征交互矩阵	充分挖掘隐含交互信息,性能改善	复杂性高,数据密集易于过拟合	商业
	AMERec <sup>[75]</sup>	ESWA,21	随机游走+深度神经网络	更灵活地从 HIN 中提取有效信息	模型的可解释性较差	
异质图嵌入	DisentHAN <sup>[68]</sup>	CIKM,20	异质图嵌入+嵌入传播层	显式探索异质图的高阶连通性	结构复杂,且难以捕捉动态交互	电影、电商
	HIN-MRS <sup>[77]</sup>	Comput,20	歌曲异质图+主题提取	计算复杂度低,具有较好解释能力	数据集较小,仅适用于音乐推荐	音乐
	SHINE <sup>[68]</sup>	WSDM,18	实体级情感提取	精确抽取用户情感关系	映射到用户编码器中的性能低下	社交网络
	SMR <sup>[78]</sup>	Big Data,21	构建医学异质图+LINE	药物推荐的结果更安全可靠	缺乏临床结果等患者信息	医疗
	DUSG <sup>[68]</sup>	FGCS,19	多类型服务数据+RAKE	计算效率高,具有良好可扩展性	关系数量对性能影响大,稳定性差	商业
	KGCN <sup>[68]</sup>	WWW,19	GCN+个性化过滤器	可灵活应用于较大的数据集	集合器忽略了实体的本身信息,相邻层间的信息无法对比	电影、图书、音乐
	KGQR <sup>[68]</sup>	SIGIR,20	GCN+强化学习	有效降低了样本复杂性和动作空间	难以建模用户的动态偏好	电影、图书
	KGenSam <sup>[68]</sup>	TKDE,21	GCN+MDP	实现了会话推荐的高效在线更新	忽略了对多回合会话场景的研究	会话推荐
	KGSF <sup>[68]</sup>	KDD,20	GCN+KG 语义融合	训练性能及稳定性较高	忽略历史交互信息且可解释性差	会话推荐
	MVIN <sup>[68]</sup>	SIGIR,20	GCN+多图图网络	高效聚合信息,灵活应用于不同领域	容易产生噪音和过拟合问题	电影、图书、音乐
基于图神经网络	InteractGC <sup>[68]</sup>	KDD,19	GCN+InteractNet+堆叠卷积	时间复杂度低,适用于大规模数据集	难以建模动态的交互和用户兴趣	电子商务
	K-NCR <sup>[68]</sup>	ESWA,21	GCN+注意力网络+NCF	显式探索 KG 语义,网络稳定性较好	训练时间长,时间复杂性高	电影、图书、音乐、商业
	KCAN <sup>[68]</sup>	CIKM,21	GCN+TransH+注意力机制	能够有效捕获细粒度的用户偏好	时间复杂度高且可解释性较差	图书、商业
	JNSKR <sup>[68]</sup>	SIGIR,20	GAT+非采样方法	层次架构简单,参数少效率高	难以在细粒度上建模实体和关系	
	KRAN <sup>[68]</sup>	TKDD,21	GAT+邻域剪枝	可灵活修改邻域实体的采样大小	还未解决用户冷启动问题	电影、图书、音乐、商业
	CRAN <sup>[68]</sup>	SIGIR,20	GAT+协同传播+KG 传播	显式编码协作信息,稳定和灵活性高	不适用于数据过于密集的场景	电影、餐饮
	MKGAT <sup>[68]</sup>	CIKM,20	GAT+多模态信息	利用多模态信息提升推荐性能	网络层数对推荐结果影响较大	
	TEKGR <sup>[68]</sup>	CIKM,20	GAT+GRU	充分考虑新闻标题的主题特征,捕获用户多样化的阅读兴趣、稳定性高	忽略了对新闻摘要和主体内容中实体的考虑	新闻
	KGNN-LS <sup>[71]</sup>	KDD,19	GNN+标签平滑正则化	模型稳定性、泛化能力和扩展性很好	隐藏层维度过大易导致过拟合	电影、图书、音乐
	KGPL <sup>[68]</sup>	WSDM,21	GNN+伪标签标记	有效降低了流行度偏差的影响	难以灵活设置损失函数中的权重	
	SMIN <sup>[68]</sup>	CIKM,21	GNN+自监督互信息学习	充分挖掘交互多维的高阶伪关系	信息传播层增加性能下降明显	社交网络

### 3.1 传统嵌入方法

TransH 作为常见的传统 KGE 方法，可用于增强推荐系统的项目表示缓解推荐冷启动问题。Cao 等<sup>[65]</sup>提出 Web 服务推荐算法（knowledge-graph based web service recommendation algorithm, KG-WSR），采用 TransH 将 Web 服务实体和用户实体嵌入到低维空间中，利用 KG 丰富信息增强 Web 服务的语义表示，有效缓解了用户交互数据稀疏和冷启动问题。针对会话推荐中的项目冷启动问

题，Meng 等<sup>[66]</sup>提出一种多任务学习模型 MKM-SR（micro-behaviors and item knowledge into multi-task learning for session-based recommendation），模型框架如图 7 所示。MKM-SR 首先从给定会话中抽取出项目序列和操作序列，然后利用 TransH 嵌入 KG 增强会话中项目的语义表示，并结合门控图神经网络（gated graph neural network, GGNN）<sup>[67]</sup>和门控循环神经网络（gated recurrent unit, GRU）学习用户交互，在冷启动场景中也具有较好的推荐性能。

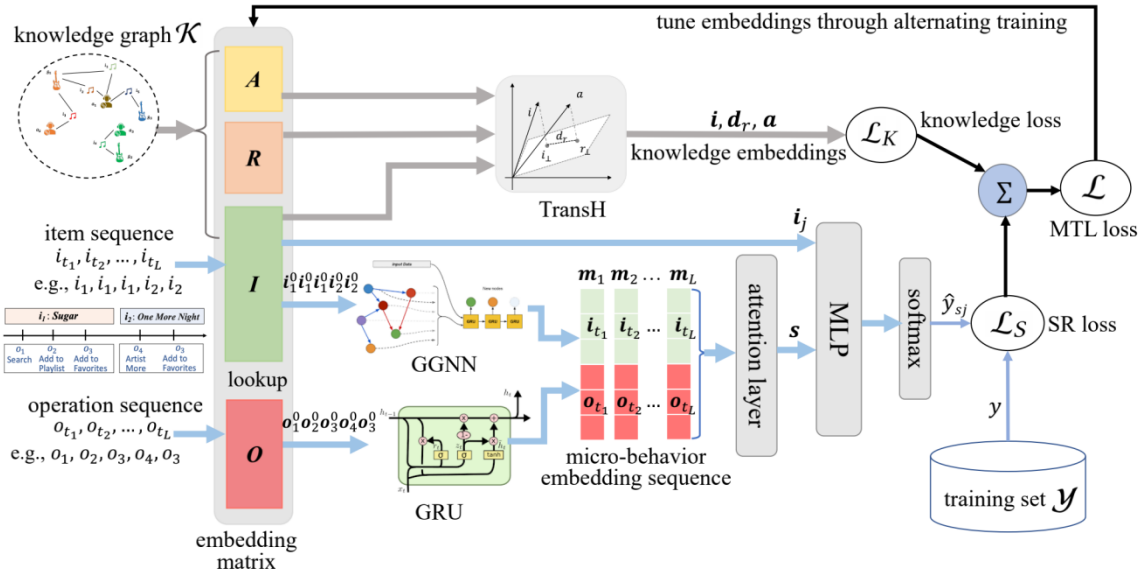


Fig.7 The overall framework of MKM-SRmodel

图 7 MKM-SR 模型总体框架

事实上一个实体往往具有多种关系，不同关系表示同一实体的多种特征，因此有研究者采用 TransR 方法在实体和关系两个不同空间中学习 KG 语义以增强数据的嵌入表征。Tang 等<sup>[68]</sup>提出注意力增强知识感知的用户偏好模型（attention-enhanced knowledge-aware user preference model, AKUPM），结合 TransR 和注意力机制分别从实体内和实体间两个方面增强实体语义，并利用实体交互信息探索用户兴趣，有效解决了用户交互数据稀疏问题。

Zhang 等<sup>[7]</sup>提出协同知识库嵌入模型（collaborative knowledge base embedding, CKE），采用 TransR 嵌入 KG 结构化知识，并融合获取到的文本嵌入表示和视觉嵌入表示从不同角度增强项目语义表示，并进一步联合用户隐式反馈缓解交互数据稀疏问题。Zhou 等<sup>[69]</sup>提出分层协同嵌入模型（hierarchical collaborative embedding, HCE），采用 TransR 嵌入 KG 实现多关系数据的建模以增强项目表示，通过构建协同学习框架丰富用户交互的稀疏语义，提升



了模型缓解冷启动问题的有效性。

鉴于 TransR 中过多参数导致计算量过大问题, 有研究者采用 TransD 嵌入知识图谱。He 等<sup>[70]</sup>提出一种电影推荐方法 HI2Rec, 基于数据集特征构造三元组以扩充 KG 信息, 采用 TransD 学习用户和项目的嵌入表示, 进而结合用户协作信息增强用户、项目及其属性的向量表示以缓解冷启动问题。Zhang 等<sup>[71]</sup>面向 App 应用推荐提出基于 KG 的卷积嵌入传播模型 (knowledge graph convolutional embedding propagation model, KGEP), 采用 TransD 建模 KG 实体和关系的一阶结构信息, 并设计图卷积网络迭代聚合实体邻域信息以捕获其高阶语义, 有效缓解了用户评分矩阵稀疏的问题。

除平移距离模型外, 也有研究者在冷启动任务中采用语义匹配模型学习 KG 嵌入表示。Wang 等<sup>[72]</sup>提出了一种多任务特征学习方法 MKR (multi-task feature learning approach for Knowledge graph enhanced Recommendation), 通过构建深层语义匹配架构学习 KG 语义, 并设计交叉压缩单元实现与推荐系统的信息共享和交换, 通过充分探索项目和实体间的高阶交互缓解数据稀疏问题, 在冷启动场景下仍具有较好的推荐性能。

### 3.2 异质图嵌入

传统 KG 嵌入方法难以高效处理包含多种类型节点和链路的异质信息, 有研究者采用嵌入异质图的方法丰富数据表征解决推荐冷启动。Shi 等<sup>[73]</sup>提出一种基于异质图嵌入的推荐方法 HERec (heterogeneous network embedding based approach), 基于随机游走策略生成异质图节点的嵌入表示并设计一组融合函数聚合节点的多个表示, 进一步集成到扩展的矩阵分解模型中生成推荐结果。HERec 利用异质图丰富语义表征用户和项目, 有助于解决冷启动问题。He 等<sup>[74]</sup>提出 HopRec, 在 HERec 基础上考虑了用户和项目间的特征交互信息, 利用特征交互矩阵表示用户和项目在不同维度上的潜在关系, 推荐性能相比 HERec 有进一步提升。Yan 等<sup>[75]</sup>提出一种基于注意力感知元路径的异质图嵌入方法 (attention-aware metapath-based network embedding for HIN based recommendation, AMERec), 如图 8 所示。AMERec 首先将异质图分解为不同元路径的加权同构网络并采用随机游走策略将其嵌入到低维向量空间中, 然后设计自注意力机制聚合不同网络中用户和项目的表示, 最后使用深度神经网络建模用户和项目间的非线性关系和潜在语义, 有效缓解了冷启动问题。

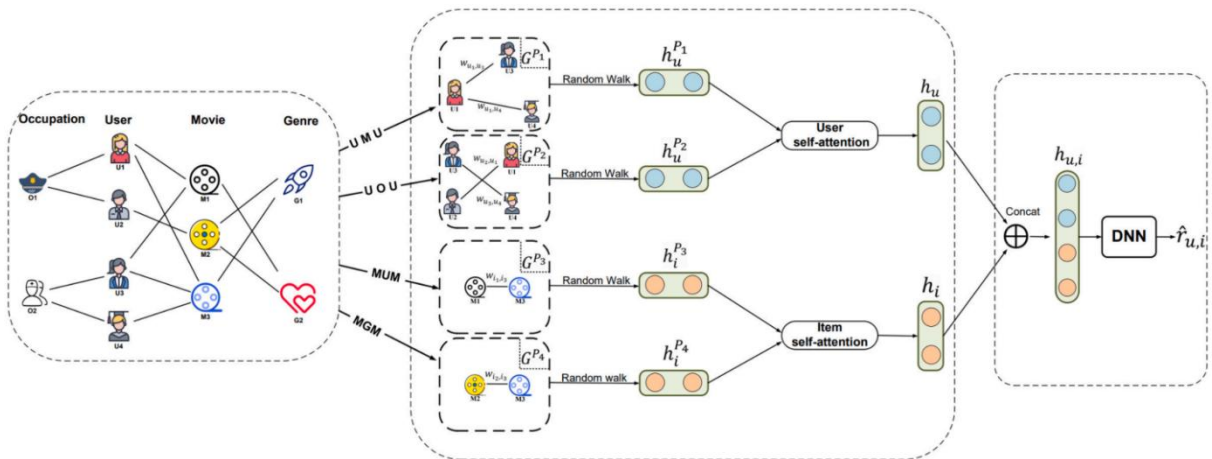


Fig.8 Framework of the AMERec model

图 8 AMERec 模型框架图



异质图蕴含的丰富语义有助于挖掘隐含交互，有利于建模细粒度用户偏好缓解推荐冷启动。Wang 等<sup>[76]</sup>提出 DisenHAN (disentangled heterogeneous graph attention network)，通过对目标节点及其单跳邻居分组捕获用户和项目的多方面语义，并堆叠多个嵌入传播层探索高阶语义以全面刻画用户特征，即便在冷启动场景下也具有较好性能。还有研究者自建异质图满足实际需求，Wang 等<sup>[77]</sup>提出 HIN-MRS (heterogeneous information network-based music recommendation system)，构建音乐异质图并根据用户上下文信息定位用户感兴趣的音乐主题，对于播放列表空的用户也能精准地推荐。Wang 等<sup>[8]</sup>提出基于情感链接的异质图嵌入方法 (signed heterogeneous information network embedding, SHINE)，采用实体级情感提取方法得到用户情感关系并设计编码器聚合对应的用户嵌入，最后采用相似性度量函数完成情感预测，在交互数据稀疏的场景下也具有较好的推荐性能。Gong 等<sup>[78]</sup>面向医学领域提出一种药物推荐方法 (safe medicine recommendation, SMR)，桥接电子病历 MIMIC-III<sup>[79]</sup>和医学知识图谱 (ICD-9 Ontology<sup>[80]</sup>和 DrugBank<sup>[81]</sup>) 构建医学异质图，并基于 LINE 模型编码实体表示，实验结果表明 SMR 有助于捕获冷启动药物和患者之间的潜在关联，在冷启动场景仍具有优越性能。Wang 等<sup>[82]</sup>提出面向领域的交互知识图谱 (domain-oriented user and service interaction knowledge graph, DUSKG)，融合多类型的服务数据并扩展文本挖掘方法 RAKE (rapid automatic keyword extraction algorithm) 从中提炼出细粒度的用户偏好信息，有效解决了用户-服务交互矩阵稀疏的问题。

### 3.3 基于图神经网络

越来越多的研究表明图神经网络方法在解决推荐冷启动问题上具有显著的效果，其中 GCN 的应用颇为广泛。Wang 等<sup>[83]</sup>提出知识图谱卷积网络 (knowledge graph convolutional networks, KGCN)，采用 GCN 有偏差地聚合实体表示，并利用 KG 高阶链接探索用户潜在兴趣，有效缓解了用户交互数据稀疏的问题，其性能相比于 RippleNet 有显著提升。Zhou 等<sup>[84]</sup>面向交互式推荐提出知识图谱增强学习框架 (knowledge graph enhanced q-learning framework for interactive recommendation, KGQR)，使用 GCN 聚合实体邻域表示以丰富项目和用户状态的表示，进一步采用强化学习方法 (deep q-learning)<sup>[85]</sup>在相关项之间传播用户兴趣以建模用户长期偏好，有效解决了用户反馈稀疏的问题。Zhao 等<sup>[86]</sup>面向会话推荐中提出知识图谱增强的采样方法 (knowledge graph-enhanced sampling, KGenSam)，利用外部知识丰富交互环境的上下文信息，基于 MDP 和 GCN 设计采样器分别对 KG 中的模糊样本和负样本进行增强进而完成推荐。KGenSam 可灵活应用于冷启动场景中，促进了会话推荐的商业化在线应用。

还有一些基于 GCN 的方法从多角度、多方面增强实体语义表示，为解决推荐冷启动问题提供了新思路。Zhou 等<sup>[87]</sup>提出一种语义融合方法 (kg-based semantic fusion, KGsf)，其关键在于使用 GCN 学习项目节点不同方面的嵌入表示，并通过互信息最大化融合面向词和项目的两个 KG 语义空间联合增强数据表示，从而准确推断冷启动设置中的用户偏好。Tai 等<sup>[88]</sup>基于 GCN 提出多视图项

目网络的架构 (multi-view item network, MVIN), 分别从用户视图和实体视图两个角度充分探索用户-实体交互和实体-实体交互。基于 GCN 设计混合层从实体交互中挖掘更全面的特征, 融合不同层中的实体表征缓解用户-项目交互稀疏的问题。Zhao 等<sup>[89]</sup>提出融入异质信息的图卷积框架 (intent graph convolution, IntentGC), 使用 GCN 学习不同异质关系的重要性以挖掘用户偏好, 通过堆叠卷积层迭代传播实体的邻域信息进而提取用户和项目间的特征交互信息, 为缓解冷启动问题提供了新思路。

Lei 等<sup>[90]</sup>提出知识图谱增强的神经协同推荐框架 (knowledge graph enhanced neural collaborative recommendation, K-NCR), 如图 9 所示。K-NCR 首先基于 GCN 挖掘 KG 高阶语义, 通过堆叠多个

卷积层建模实体上下文信息。然后设计注意力网络学习用户交互项和候选项的权重信息, 带权聚合后得到用户表示。最后将项目和用户的表示输入到神经协同过滤模型 (neural collaborative filtering, NCF) 中学习其交互特征, 输出用户对项目的潜在偏好。K-NCR 刺激用户偏好在实体集上的传播, 解决了传统 NCF 存在的冷启动问题及其难以建模 KG 高阶连通性的局限性。Tu 等<sup>[91]</sup>提出一种知识感知的条件注意力网络 (Knowledge-aware Conditional Attention Networks, KCAN), 结合 TransH 和 GCN 捕获实体的高阶连通性, 基于实体的注意力权重构建相应子图, 并在传播过程中将个性化信息融入到子图中, 能够有效捕获细粒度用户偏好, 在冷启动场景中仍具有较好性能。

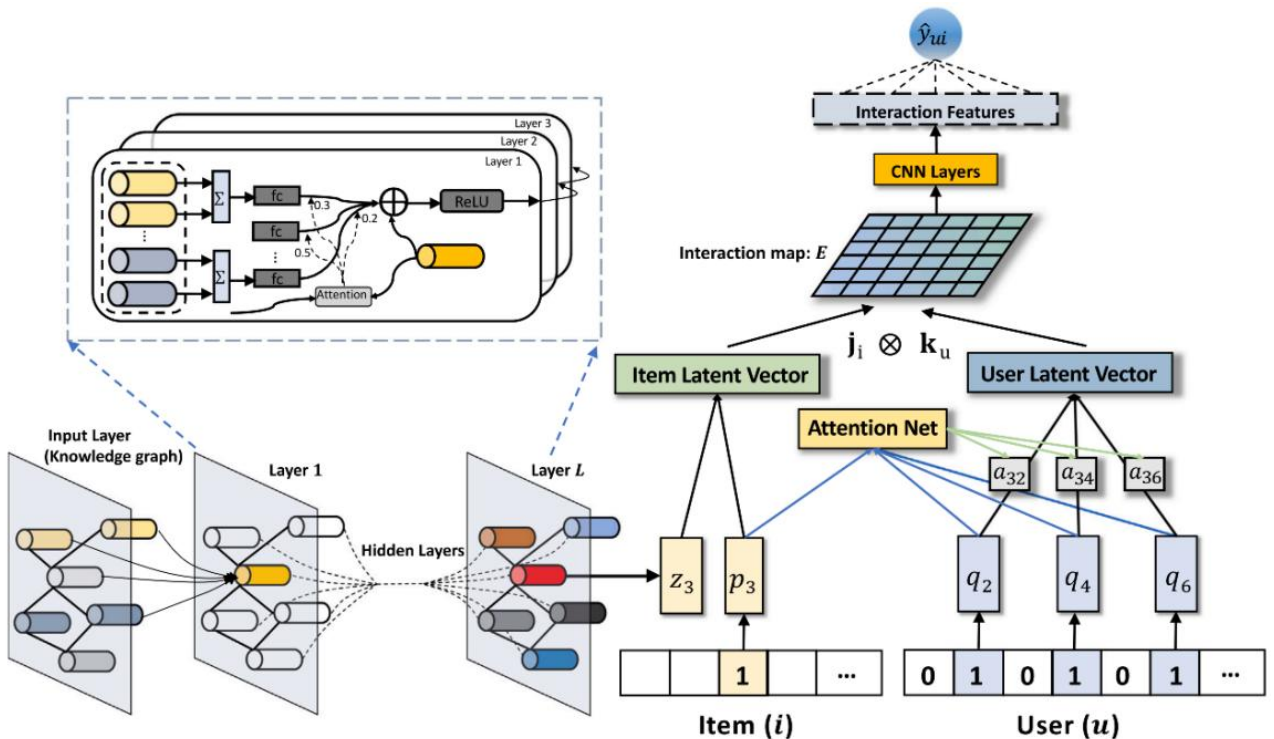


Fig.9 The overall framework of K-NCR model

图 9 K-NCR 模型总体框架

此外,基于 GAT 嵌入表示知识图谱的研究在冷启动任务中也受到了越来越多学者的关注。Chen 等<sup>[92]</sup>提出联合非采样方法的 KG 学习模型 (jointly non-sampling learning model, JNSKR), 采用 GAT 带权聚合实体及其邻域信息以建模细粒度用户偏好, 并联合非采样方法共同学习 KG 嵌入表示, 有效解决了用户交互数据稀疏的问题, 其推荐性能相比 RippleNet 和 KGAT 等基线有显著提升。Zhang 等<sup>[93]</sup>基于 KG 提出注意力网络 KRAN (knowledge refining attention network), 通过细化权重系数有针对性地聚集实体邻域信息, 多次聚合后增强重要邻域信息并不断剔除相关性较低的邻域, 可以较为有效解决项目冷启动问题。Wang 等<sup>[94]</sup>提出协同知识感知注意力网络 (collaborative knowledge-aware attentive network, CKAN), 基于 GAT 充分捕获 KG 高阶语义以探索用户潜在偏好, 并结合协同传播和 KG 传播增强用户和项目的嵌入表示, 在冷启动场景下具有较好推荐性能。此外, 还有研究者创新性使用 GAT 整合多模态信息缓解冷启动问题, Sun 等<sup>[95]</sup>提出多模态 KG 注意网络 (multi-modal knowledge graph attention network, MKGAT), 使用 GAT 整合知识图谱的结构知识、图像和文本等多模态信息以增强实体的嵌入表示, 其推荐性能相比于 KGAT 等基线具有显著改进。

图神经网络还可以结合其他一些方法缓解冷启动问题, 如门控循环单元、标签平滑正则化和异质信息等。Lee 等<sup>[96]</sup>提出基于知识图谱嵌入的新闻文档表示增强方法 (topic-enriched knowledge graph recommendation system, TEKGR), 基于双向门控循环单元 (bidirectional gated recurrent units,

Bi-GRU) 和 GNN 设计词级和知识级新闻编码器联合学习新闻表示, 从语义层和知识层两个角度增强新闻文档表示。TEKGR 利用 KG 丰富语义挖掘实体间的主题关系和上下文特征提高新闻建模的准确度, 有助于解决冷启动问题。Wang 等<sup>[97]</sup>提出基于标签平滑正则化的知识感知方法 (knowledge-aware graph neural networks with label smoothness regularization, KGNN-LS), 然后结合 GNN 和标签平滑正则化方法传播 KG 实体特征和标签信息, 充分学习用户个性化偏好以缓解冷启动问题, 不同数据集下的推荐性能都优于 RippleNet。受 KGNN-LS 的启发, Togashi 等<sup>[98]</sup>提出 KGPL (KG-aware recommender based on GNNs and pseudo-labelling), 采用 GNN 将知识图谱中有标签节点的特征传播到未标签的节点, 基于伪标签的半监督式学习方法预测样本标签, 通过增加样本的标签缓解冷启动问题, 推荐性能相比于 KGNN-LS 有进一步提升。Long 等<sup>[99]</sup>提出自监督元图信息网络 (self-supervised metagraph informax network, SMIN), 设计异质图神经网络聚合不同类型关系的特征嵌入, 并将聚合结果输入到自监督互信息学习范式中建模用户-项目的高阶连通性。SMIN 联合社交网络和 KG 信息从多方面挖掘细粒度用户偏好, 有助于缓解冷启动问题。

### 3.4 小结

进一步从推荐性能、模型可扩展性等角度出发挖掘面向推荐冷启动任务的 KGE 应用方法间的关联性, 可以得到如图 10 所示的方法关联图。

其中, HCE、HERec 和 AKUPM 分别通过构建

协同学习框架、挖掘异质信息和设计注意力机制提升推荐性能,相较于 CKE 推荐精度提升显著,AKUPM在 MovieLens 和 Book-Crossing 数据集上的 CTR 预测精度提升达 15.9%和 36.3%;KGEP 则通过设计图卷积网络弥补了HCE难以探索 KG 高阶语义的局限性;HopRec、AMERec 和 SMIN 采用不同策略挖掘异质图的深层语义,相比 HERec 具有更优越的性能, HopRec 在 Yelp 和 DoubanBook 数据集上的推荐性能相比 HERec 有 2.85%-6.11%的提升,AMERec 有 1.21%-7.87%的提升;MKR 则通过构建深层语义匹配架构进一步解决了 AKUPM 难以建模高阶连通性的不足。

MKGAT、JNSKR 和 KCAN 从不同角度提升信息处理效率,相比 CKE 和 KGAT 具有更高的推荐

性能和精度, MKGAT 在 MovieLens 和 Dianping 数据集上的改进达 3.1%-10.1%, JNSKR 和 KCAN 在 Yelp 数据集上的改进分别为 7.26%-13.13%和 1.6%-9.8%。KGCN 和 KGNN-LS 相比 CKE 和 RippleNet 具有更好的泛化能力和可扩展性;K-NCR 和 MVIN 解决了 KGCN 难以充分挖掘实体间复杂交互特征的局限性,在 Last.FM 数据集上的 AUC 值分别提升了 3.0%和 5.0%;KRAN 通过细化权重系数有效提升了推荐性能,在不同数据集上的 AUC 和 F1 值相比 KGCN 都有改进,且 KRAN 具有更好的可扩展性;CKAN 和 KGPL 采用不同策略进一步提升了模型的稳定性和灵活度,相较于 KGNN-LS 在 Last.FM 和 Book-Crossing 数据集上的性能指标都有显著提升。

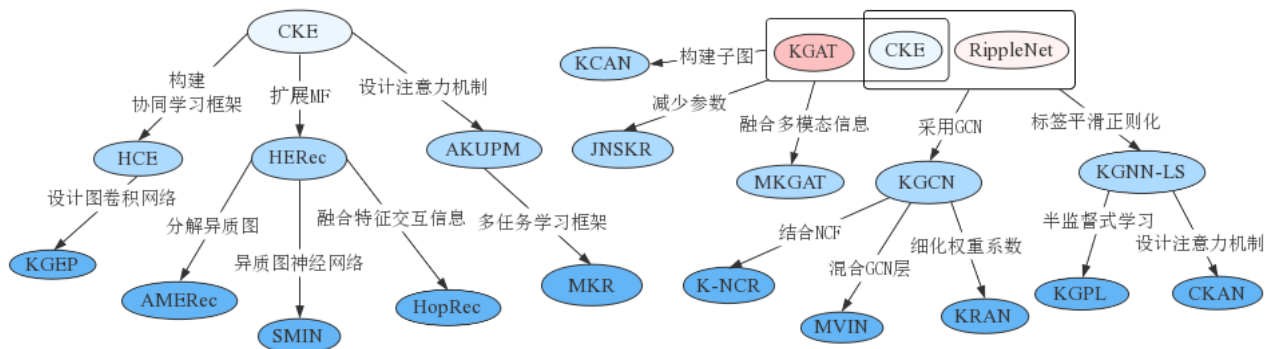


Fig.10 KGE application method association graph for coldstart task

图 10 面向推荐冷启动任务的 KGE 应用方法关联图

#### 4 序列化推荐任务

KGE 方法除了用于提升推荐可解释性和增强冷启动任务中的数据表示之外,其在学习序列化数据方面也具有优越性能,有助于捕捉动态变化的用

户偏好。和解决推荐冷启动问题类似,面向序列化推荐任务中的常用方法包括传统嵌入、异质图嵌入和基于图神经网络的方法,方法的应用创新及特征对比如表 3 所示。

Table 3 Comparison of KGE application methods for serialization recommendation tasks

表 3 面向序列化推荐任务的 KGE 应用方法对比

嵌入方法	模型框架	会议	创新应用	优点	局限性	应用场景
传统嵌入方法	KSR <sup>[21]</sup>	SIGIR.18	TransE+KV-MN+GRU	同时具有 GRU++和 KV-MN 的优点，性能稳定且推荐结果高度可解释	包含大量参数，结构较复杂，复杂性高且扩展性差	电影,图书,音乐
	会话推荐算法 <sup>[101]</sup>	Information.20	TransE+GNN+KV-MN	充分挖掘用户的长期和短期偏好，在冷启动场景下仍保持较好性能	模型性能很大程度上受所构造会话图质量的影响	电影,图书(会话推荐)
	Chorus <sup>[102]</sup>	SIGIR.20	TransE+时间核函数	整合时间信息捕捉动态的用户需求和项目语义，具有较高的可解释性	当关系信息过于稀疏或过于复杂时模型性能较差，且稳定性差	电子商务
	KAeDCN <sup>[103]</sup>	CIKM.21	TransE+动态卷积网络	收敛速度和泛化性能较好	数据集大小对模型性能影响较大	电影,书籍,音乐,电商
	KERL <sup>[104]</sup>	SIGIR.20	TransE+MDP+GRU	高效利用知识信息实现序列化推荐	提升知识探索长度会降低性能	
	因子分解模型 <sup>[105]</sup>	SIGIR.19	TransE+NF+LSTM	充分挖掘用户项目之间更深层次的关联，且模型效率较高	实验集和测试集很小且基线较少，无法进行有力的对比分析	电子商务
	MRP2Rec <sup>[106]</sup>	IEEE.20	TransR+LSTM	能够充分利用 KG 语义挖掘多关系路径，有效解决了数据稀疏性问题	路径长度会影响性能，忽略了对实体类型重要性的考虑	电影,图书
	MKM-SR <sup>[69]</sup>	SIGIR.20	TransH+GCNN+GRU	生成更细粒度的会话表示和用户偏好，在冷启动场景中仍具有较好性能	模型收敛性较差且复杂度高，联合训练的实验结果较差	电商,音乐(会话推荐)
	HERec <sup>[73]</sup>	TKDE.19	异质图嵌入+矩阵分解	能够更有效地提取和利用 KG 信息，有利于改善冷启动问题	模型扩展性较差且其复杂性受路径质量的影响	电影,图书,商业
	HopRec <sup>[24]</sup>	ESWA.21	HERec+特征交互矩阵	在 HERec 基础上融合交互特征挖掘更多的隐含信息	复杂性较高，当数据密集时特征交互易于过拟合	POI 推荐
异质图嵌入	HI-LDA <sup>[109]</sup>	Neurcomputing.20	多个社交网络异质信息+MCMC+IPO	利用文本信息挖掘用户潜在偏好	模型迭代采样和文本分析的计算复杂度更高，训练时间较长	
	SMR <sup>[81]</sup>	Big Data.21	医学异质图+LINE	缓解冷启动问题，药物推荐结果可靠	缺乏充足患者信息，如临床结果	
	DKN <sup>[111]</sup>	WWW.18	GNN+卷积神经网络	高效学习新闻句子语义，保留单词与实体间关联，捕捉多样化的阅读兴趣	忽略了对新闻主体内容中实体的考虑，不适用于其他领域	医疗
	KIM <sup>[112]</sup>	SIGIR.21	GAT+卷积神经网络+交互学习	充分挖掘新闻之间的语义关联，提升了用户和候选新闻的匹配度	性能稳定性受编码器网络层数的影响，且训练时间较长	新闻

#### 4.1 传统嵌入方法

TransE 作为一种常见的 KGE 方法,在序列推荐任务中的应用也十分广泛。Huang 等<sup>[21]</sup>提出知识增强的序列化推荐模型 (knowledge-enhanced sequential recommender, KSR),在 TransE 基础上结合循环神经网络 (recurrent neural networks, RNN) 和键值对记忆网络 (key-value memory networks, KV-MN)<sup>[100]</sup>建模用户的序列化偏好和基于项目属性的偏好,融合两者得到细粒度的用户偏好表示,有效提升了序列化推荐精度。Wang 等<sup>[101]</sup>进一步对模型改进提出一种会话推荐算法,使用 GNN 替代 RNN 捕获交互序列中项目的复杂转换,其推荐性能相较于 KSR 有提升。算法另一创新点还在于将分离的会话序列建模为会话图,并使用 TransE 和 KV-MN 获得基于 KG 语义的用户偏好,然后将其与

GNN 建模得到的用户序列化偏好拼接成最终的用户偏好表示。Wang 等<sup>[102]</sup>针对推荐过程中动态变化的用户需求提出时间感知模型 Chorus,采用 TransE 嵌入项目和项目间的关系,并将其与交互序列、交互时间差等融合,进一步设计出时间核函数建模项目在不同序列中的动态语义,提升了推荐效果。Liu 等<sup>[103]</sup>结合注意力机制和动态卷积网络,提出一种知识感知的序列化推荐算法 (knowledge-aware sequential recommender with the attention-enhanced dynamic convolutional network, KAeDCN),如图 11 所示。KAeDCN 使用 TransE 获得项目的属性级信息,设计特征增强模块从不同维度挖掘项目语义,进一步将其输入到动态卷积网络中捕获其动态依赖关系。KAeDCN 能够准确挖掘项目之间的动态依赖关系,提高了序列依赖性的可提取性。

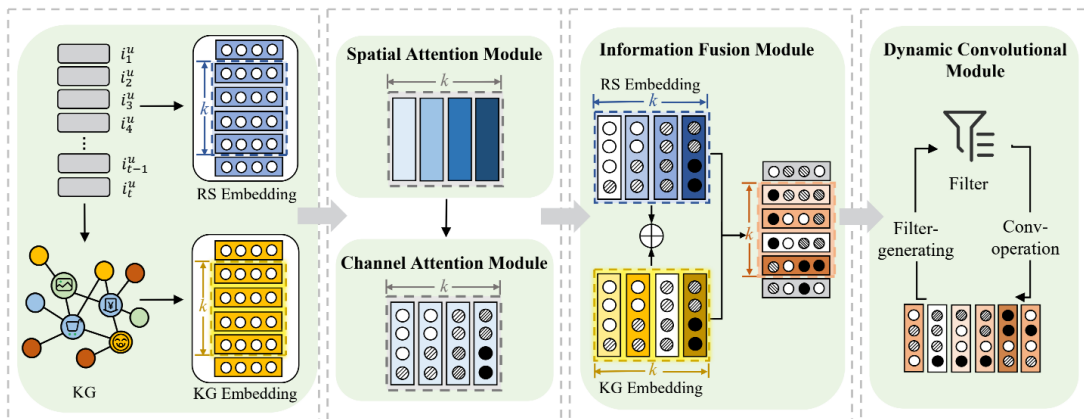


Fig.11 The framework of model KAeDCN

图 11 KAeDCN 模型框架

Wang 等<sup>[104]</sup>提出一种基于知识图谱嵌入的强化学习模型 (knowledge-guided reinforcement learning model, KERL),核心在于将序列化推荐形式化为 MDP 过程。利用 TransE 和 GRU 分别从知识图谱和交互序列中获取项目知识级和序列级的表示,从而准确地预测用户偏好和行为。Chowdhury 等<sup>[105]</sup>则将

基于 TransE 得到的 KG 嵌入表示进一步集成到神经因子分解模型 (neural factorization, NF)<sup>[106]</sup>中捕捉实体间的复杂关系,并设计带注意力机制的 LSTM 学习用户的历史行为以建模用户序列化偏好,实验表明模型在预测用户行为上具有较好性能。



还有研究者采用 TransR 和 TransH 方法替代 TransE，避免了无法充分建模复杂关系的局限性。Wang 等<sup>[107]</sup>基于知识图谱推荐提出多步关系路径语义的获取方法（multiple-step relation path semantics for knowledge graph based recommendations，MRP2Rec），结合 TransR 和 LSTM 学习协同知识图谱中关系路径的高阶语义，并根据多关系路径提取用户和项目的表示，MRP2Rec 通过学习用户行为特征提升了序列化推荐的精度。文献[66]提出的 MKM-SR，利用 TransH 嵌入 KG 增强项目语义表示，在其基础上结合 GGNN 和 GRU 学习用户序列化偏好，进一步将其输入到多任务学习范式（multi-task learning，MTL）<sup>[108]</sup>中预测用户交互，模型在缓解冷启动问题的同时有效提升了序列化推荐性能。

## 4.2 异质图嵌入

还有研究者采用异质图嵌入方法增强序列信息表示用于提升推荐精度。文献[73]提出的 HERec 方法，采用随机游走方式学习包含用户、项目和项目属性的异质图嵌入表示，并将其集成到扩展的矩阵分解模型中完成推荐点击预测，提升了推荐效果。文献[74]在 HERec 基础上提出 HopRec，将用户和项目的嵌入表示进行外积（outer product）操作获得二维特征交互矩阵（feature interaction matrix）以挖掘用户和项目在不同维度上的潜在关系，进一步提升序列化推荐性能。然而当用户和项目数据较为稠密时，该模型容易出现过拟合现象。

Xiong 等<sup>[109]</sup>提出基于异质图嵌入的概率生成模型（heterogeneous information based lda，HI-LDA），

结合基于位置和通信两大社交网络上的多种异质信息联合建模用户交互行为，基于 MCMC（markov chain monte carlo）<sup>[110]</sup>方法生成用户兴趣点分布序列提升推荐效果。在医学领域中，文献[78]提出通过构建医学异质图充分学习患者、疾病和药物间的潜在联系，分析患者患病和服药的时序关系，实现药物对患者的链接预测，提升了药物推荐精度。

## 4.3 基于图神经网络

除上述方法外，还有研究者采用 GNN 探索 KG 语义以提升序列化推荐性能。Wang 等<sup>[111]</sup>面向新闻推荐提出深度知识感知网络（deep knowledge-aware network，DKN），设计卷积神经网络融合新闻语义层和知识层信息，从而得到用户历史点击序列和候选新闻的嵌入表示，最终聚合这些新闻表示获得用户偏好，推荐性能提升显著。然而 DKN 建模候选新闻时忽略了对目标用户的考虑，不利于候选新闻和用户兴趣的匹配。Qi 等<sup>[112]</sup>则提出知识感知的交互匹配方法（knowledge-aware interactive matching，KIM），通过交互学习历史点击新闻和候选新闻的知识感知表示提高用户点击候选新闻的预测精度，如图 12 所示为模型整体架构和知识感知的新闻协同编码器设计。KIM 采用 GAT 获得候选新闻和用户历史点击序列的知识表示，并结合 CNN<sup>[113]</sup>获得基于文本语义的新闻表示，对得到的两种新闻表示进行交互式学习最终获得针对候选新闻的用户偏好表示和用户感知的候选新闻表示，从而完成兴趣匹配。多个新闻数据集上的实验结果表明 KIM 相比于 KRED 和 DKN 等新闻推荐算法均有较好改进。

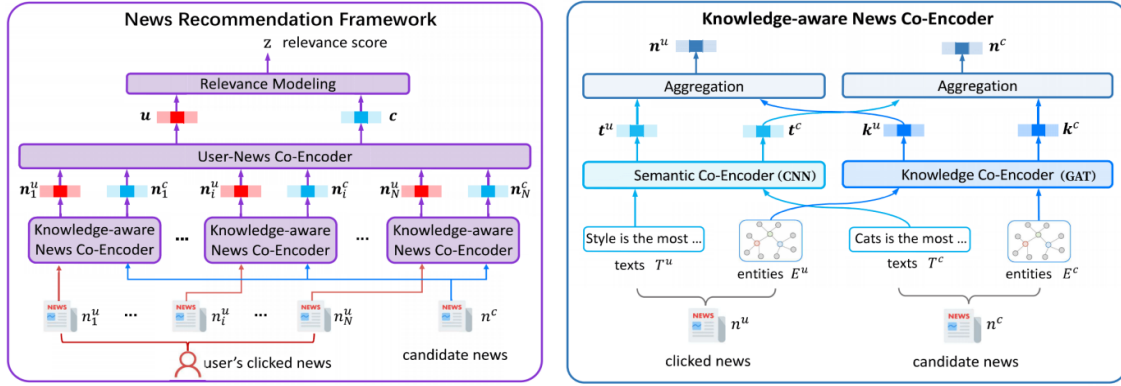


Fig.12 The overall framework of KIM and the knowledge-aware news co-encoder

图 12 KIM 模型总体框架和知识感知的新闻协同编码器

#### 4.4 小结

进一步对面向序列化推荐任务的 KGE 应用方法间的相关性进行归纳分析,可以得到如图 6 所示的方法关联图。

KSR 结合 RNN 和 KV-MV 构建序列化推荐框架,有助于挖掘动态的用户偏好,然而模型存在复杂性高、扩展性差和难以建模项目间复杂关系等局限性。算法 [101]使用 GNN 替代 RNN 建模用户兴趣偏好,降低计算时间复杂度的同时提升了模型可扩展性,不同数据集上的 Recall 值有 2.6%-6.3%的提升;KERL 利用 MDP 构建强化学习模型,相比 KSR 有效提升了对项目复杂关系的建模能力,Amazon 和 Last.FM 数据集上的

NDCG 值提升达 2.2%-5.8%;KAeDCN 则通过设计动态卷积网络挖掘动态变化的用户偏好,进一步提升了模型的收敛速度和泛化性能。

Chorus 在建模实体和关系时融合了时间信息,相较于 DKN 能够更准确地捕获项目的动态语义;MRP2Rec 则基于多步关系路径语义挖掘用户的行为特征,在 MovieLens 和 Book-Crossing 数据集上的 ACC 值相较于 DKN 分别提升了 44.26%和 13.79%。在新闻推荐领域,KIM 通过交互式学习提升推荐精度,相比独立建模候选新闻和用户兴趣的方法具有更高的匹配度,在 MIND 数据集上的 AUC 值提升了 4.76%。

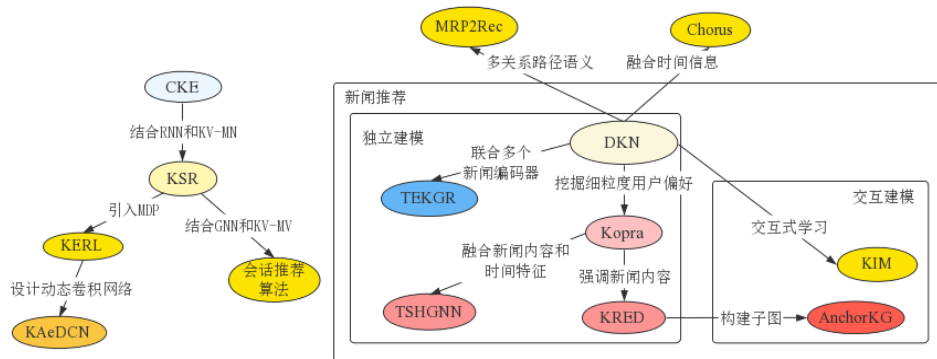


Fig.13 KGE application method association graph for serialization recommendation task

图 13 面向序列化推荐任务的 KGE 应用方法关联图

## 5 未来发展方向

近年来推荐研究领域已有大量基于知识图谱嵌入研究工作, 本文对知识图谱嵌入在不同推荐任务中的应用研究进行了系统综述, 下面对未来该领域值得关注的几个发展方向进行展望。

**基于图神经网络增强知识图谱嵌入。**图神经网络通过聚合图中相邻节点增强语义表示能够充分捕获图数据的结构依赖性, 特别适合实现不同类型 KG 的嵌入学习, 已被广泛应用于可解释推荐和面向冷启动的推荐任务中。此外, 还可以探讨结合其他类型图神经网络方法的应用, 如图自编码器 (graph autoencoders, GAE)、图生成网络 (graph generative networks, GGN) 以及图时空网络 (graph spatial-temporal networks, GSTN) 等<sup>[114]</sup>, 进一步从模型变体及模型混合两个角度建模空间和时间依赖性生成可信的补充知识以增强知识图谱的嵌入效果。事实上, 知识图谱可以看做是一种特殊的异质图<sup>[115]</sup>, 将图神经网络和异质图表示学习研究相结合, 研究如何在异质图一样学习节点和边的语义、如何从多个维度融合节点表示提升知识图谱嵌入效果也具有研究意义。在此基础上, 可以进一步深入探索其在序列化推荐任务中的应用。

**借鉴多领域方法探索推荐任务中的知识图谱语义应用。**在不同推荐任务中, 知识图谱嵌入实现大都属于上游工作, 紧随其后的下游工作应用模型包括 MDP、KV-MN、LSTM、GRU、CNN 和协同过滤等多领域方法, 其融合应用在增强推荐可解释性、缓解冷启动问题以及提升序列化推荐精度上都有较好效果。显然, 在下游工作中还有待开采不同领域算法以增强知识图谱嵌入在推荐任务中的应用效果。因此可以在下游工作中进一步探索深度学习、网络表示学习和图学习以及多模态学习等不同领域算法与 KGE 的融合方式<sup>[12,116,117]</sup>, 探索其不同推荐任务中的应用。比如文献[74]基于矩阵分解

和随机游走的图学习方法捕获 KG 实体不同维度上的潜在关联进而缓解冷启动问题; 文献[111,112]基于网络表示学习方法更全面地挖掘知识图谱的高阶语义信息, 有助于提升序列化推荐精度。综上所述, 推荐任务中的知识图谱嵌入与其他领域算法的创新融合方式及应用具有一定研究价值。

**多元数据融合提升知识图谱嵌入应用效果。**在知识图谱嵌入基础上融合其他类型数据可以从不同角度增强推荐任务中的项目和用户嵌入表示, 在可解释推荐和面向冷启动的推荐任务中有较好的应用效果。例如, 融合不同类型数据实现多模态知识图谱 (multi-modal knowledge graph, MKG) 的嵌入应用、融合时间戳信息和关系时效性实现动态知识图谱的嵌入应用<sup>[17]</sup>、在知识图谱外部增设其它种类数据构建多层次的项目或用户表示等。其中, 多模态知识图谱融合语义知识图谱和丰富的文本、图像和多媒体等模态数据, 具有更全面的关系类型和关系数量, 可以为知识表示学习和解释推荐产生的原因提供视觉和文本支撑<sup>[7]</sup>。此外, 动态知识图谱融合时间戳信息学习实体的动态演化规律, 从时间和空间维度增强实体的语义表示, 有助于在推荐任务中挖掘关系时效性并提升推荐可解释性, 可以根据实体的动态演化规律进一步探索其序列化特征; 与嵌入应用多模态知识图谱不同, 可以在知识图谱外部增设其它类型数据, 从结构化 KG 知识、文本和其它多模态信息等不同角度建模多层次的用户或项目嵌入表示。

## 6 总结

知识图谱嵌入有助于解决推荐任务中存在的可解释性差、冷启动问题和序列化推荐建模等问题, 在提升推荐系统性能上具有显著效果, 目前已被广泛应用于各类推荐任务中。本文在充分调研近年来该领域的相关研究之后简单回顾了应用 KGE 方法的常见推荐任务, 归纳总结出作为上游任务的 KGE

方法应用目的及类别, 然后进一步对其与下游任务中其他方法的创新融合策略及应用特征进行系统性总结和介绍。最后展望了未来该研究的发展趋势, 提出了几个值得关注的发展方向, 希望这篇文章可以为该领域的发展提供新的见解, 促进该领域的持续发展和进步。

## 参考文献:

- [1] ADOMAVICIUS G, TUZHILIN A. Towards the next generation of recommender systems: A survey of the state-of-the-art and possible extensions[J]. IEEE Transactions on Knowledge and Data Engineering, 2005. 17(6): 734-749.
- [2] DU X Y, HE X N, YUAN F J, et al. Modeling embedding dimension correlations via convolutional neural collaborative filtering[J]. ACM Transactions on Information Systems, 2019. 37(4).
- [3] ZHANG F Z, YUAN J NICHOLAS, LIAN D F, et al. Collaborative knowledge base embedding for recommender systems[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, CA, USA, August 13-17, 2016: 353-362.
- [4] WANG H W, ZHANG F Z, HOU M, et al. SHINE: Signed heterogeneous information network embedding for sentiment link prediction[C]//Proceedings of the 11th ACM International Conference on Web Search and Data Mining, Marina Del Rey, CA, USA, February 5-9, 2018: 592-600.
- [5] BOLLACKER K, EVANS C, PARITOSH P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]//Proceedings of the ACM SIGMOD International Conference on Management of Data, Vancouver, BC, Canada, June 10-12, 2008: 1247-1250.
- [6] LEHMANN J, ISELE R, JAKOB M, et al. DBpedia-A large-scale, multilingual knowledge base extracted from Wikipedia[J]. Semantic Web, 2015. 6(2): 167-195.
- [7] SUCHANEK F M, KASNECI G, WEIKUM G. Yago: a core of semantic knowledge[C]//Proceedings of the 16th International Conference on World Wide Web, Banff, Alberta, Canada, May 8-12, 2007. ACM 2007: 697-706.
- [8] CARLSON A, BETTERIDGE J, KISIEL B, et al. Toward an architecture for never-ending language Learning[C]//Proceedings of the 24th AAAI Conference on Artificial Intelligence, Atlanta, Georgia, USA, July 11-15, 2010.
- [9] NICKEL M, TRESP V, KRIEGEL H-P, A three-way model for collective learning on multi-relational data[C]//Proceedings of the 28th International Conference on Machine Learning, Bellevue, Washington, USA, June 28-July 2, 2011: 809-816.
- [10] WANG Z, ZHANG J W, FENG J L, et al. Knowledge graph embedding by translating on hyperplanes[C]//Proceedings of the 28th AAAI Conference on Artificial Intelligence, July 27-31, Québec City, Québec, Canada, 2014: 1112-1119.
- [11] LIN Y K, LIU Z Y, SUN M S, et al. Learning entity and relation embeddings for knowledge graph completion [C]//Proceedings of the 29th AAAI Conference on Artificial Intelligence, Austin, Texas, USA, January 25-30, 2015: 2181-2187.
- [12] TIAN X, DING Q, LIAO ZH, SUN GD. Survey on deep learning based news recommendation algorithm[J]. Journal of Frontiers of Computer Science and Technology, 2021, 15(6): 971-998.
- 田萱, 丁琪, 廖子慧, 孙国栋. 基于深度学习的新闻推荐算法研究综述[J]. 计算机科学与探索, 2021, 15(6): 971-998.
- [13] PALUMBO E, RIZZO G, TRONCY R. Entity2rec: learning user-item relatedness from knowledge graphs for top-n item recommendation[C]//Proceedings of the 11th ACM Conference on Recommender Systems, Como, Italy, August 27-31, 2017: 32-36.
- [14] WANG X Y, ZHANG Y, WANG X L, et al. A knowledge graph enhanced topic modeling approach for herb recommendation[C]//Proceedings of the 24th International Conference on Database Systems for Advanced Applications, Chiang Mai, Thailand, April 22-25, 2019: 709-724.
- [15] HUANG H H. An MPD player with expert knowledge-based single user music recommendation[C]//Proceedings of the International Conference on Web Intelligence, Thessaloniki, Greece, October 14-17, 2019: 318-321.
- [16] WANG Q, MAO Z D, WANG B, et al. Knowledge graph embedding: A survey of approaches and applications[J]. IEEE Transactions on Knowledge and Data Engineering, 2017. 29(12): 2724-2743.
- [17] QIN C, ZHU H S, ZHUANG F Z, et al. A survey on knowledge graph-based recommender systems[J]. Science China Information Science, 2020, 50: 937-956, doi:

- 10.1360/SSI-2019-0274
- 秦川, 祝恒书, 庄福振, 等. 基于知识图谱的推荐系统研究综述[J]. 中国科学: 信息科学, 2020, 50: 937-956, doi: 10.1360/SSI-2019-0274"
- [18] ZHU D L, WEN Y, WAN Z C. A survey on knowledge graph-based recommender systems[J]. Data analysis and knowledge discovery: 1-16 [2021-11-02]. HTTP://http://kns.cnki.net/kcms/detail/10.1478.G2.20211020.1438.004.html.
- 朱冬亮, 文奕, 万子琛. 基于知识图谱的推荐系统研究综述[J/OL]. 数据分析与知识发现: 1-16[2021-11-02]. http://kns.cnki.net/kcms/detail/10.1478.G2.20211020.1438.004.html."
- [19] TINTAREV N, MASTHOFF J. Designing and evaluating explanations for recommender systems[M]. Recommender Systems Handbook. 2011: 479-510.
- [20] QUADRANA M, KARATZOGLOU A, HIDASI B, et al. Personalizing session-based recommendations with hierarchical recurrent neural networks[C]//Proceedings of the 11th ACM Conference on Recommender Systems. Como, Italy, August 27-31, 2017: 130-137.
- [21] HUANG J, ZHAO W X, DOU H J, et al. Improving sequential recommendation with knowledge-enhanced memory networks[C]//Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval. 2018, Ann Arbor, MI, USA, July 08-12, 2018: 505-514.
- [22] ZHANG Y F, CHEN X. Explainable recommendation: A survey and new perspectives[J]. Foundations and Trends in Information Retrieval, 2020. 14(1): 1-101.
- [23] WANG S J, HU L, WANG Y, et al. Sequential recommender systems: challenges, progress and prospects [C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence, Macao, China, August 10-16, 2019: 6332-6338.
- [24] WANG H W, ZHANG F Z, WANG J L, et al. Exploring high-order user preference on the knowledge graph for recommender systems[J]. ACM Transactions on Information Systems, 2019. 37(3): 32:1-32:26.
- [25] HUANG X W, FANG Q, QIAN S S, et al. Explainable interaction-driven user modeling over knowledge graph for sequential recommendation[C]//Proceedings of the 27th ACM International Conference on Multimedia, MM 2019, Nice, France, October 21-25, 2019: 548-556.
- [26] KAEHLING L P, LITTMAN M L, MOORE A W. Moore, Reinforcement learning: A survey[J]. Journal of Artificial Intelligence Research, 1996. 4: 237-285.
- [27] HOCHREITER S, SCHMIDHUBER J. Long Short-Term Memory[J]. Neural Computation, 1997. 9(8): 1735-1780.
- [28] KRIZHEVSKY A, SUTSKEVER I, HINTON G. ImageNet classification with deep convolutional neural networks [C]//Proceedings of the 26th Annual Conference on Neural Information Processing Systems, Lake Tahoe, Nevada, December 3-6, 2012. 25(2): 1106-1114
- [29] BORDES A, USUNIER N, GARCÍA-DURÁN A, et al. Translating embeddings for modeling multi-relational data[C]//Proceedings of the 27th Annual Conference on Natural Information Processing Systems. Proceedings of a meeting held December 5-8, 2013, Lake Tahoe, Nevada, United States.2013: 2787-2795.
- [30] JI G L, HE S Z, XU L H, et al. Knowledge graph embedding via dynamic mapping matrix[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing of the Asian Federation of Natural Language Processing, July 26-31, 2015: 687-696
- [31] XIAN Y K, FU Z H, MUTHUKRISHNAN S, et al. Reinforcement knowledge graph reasoning for explainable recommendation[C]//Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, Paris, France, July 21-25, 2019:285-294
- [32] SHA X, SUN Z, ZHANG J. Attentive knowledge graph embedding for personalized recommendation[J]. CoRR, 2019. abs/1910.08288.
- [33] SHI C, LI Y T, ZHANG J W, et al. A survey of heterogeneous information network analysis[J]. IEEE Transactions on Knowledge and Data Engineering, 2017. 29(1): 17-37.
- [34] CAI H Y, ZHENG V W, CHANG C C. A comprehensive survey of graph embedding: problems, techniques and applications[J]. IEEE Transactions on Knowledge and Data Engineering.2018: 1616-1637
- [35] KIPF T N., WELING M. Semi-supervised classification with graph convolutional networks[C]//Proceedings of the 5th International Conference on Learning Representations, Toulon, France, April 24-26, 2017.
- [36] VELICKOVIC P, CUCURULL G, CASANOVA A, et al. Graph attention networks[C]//Proceedings of the 6th In-

- ternational Conference on Learning Representations, Vancouver, BC, Canada, April 30-May 3, 2018
- [37] AI Q Y, AZIZI V, CHEN X, et al. Learning heterogeneous knowledge base embeddings for explainable recommendation[J]. *Algorithms*, 2018. 11(9): 137.
- [38] TIAN Y, YANG Y H, REN X D, et al. Joint knowledge pruning and recurrent graph convolution for news recommendation[C]//*Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*, Virtual Event, Canada, July 11-15, 2021: 51-60.
- [39] ZHANG Y F, AI Q Y, CHEN X, et al. Learning over knowledge-base embeddings for recommendation[J].. *CoRR*, 2018. abs/1803.06540.
- [40] LIU D Y, LIAN J X, WANG S Y, et al. KRED: Knowledge-aware document representation for news recommendations[C]//*Proceedings of the 14th ACM Conference on Recommender Systems*, Virtual Event, Brazil, September 22-26, 2020: 200-209.
- [41] MA C, MA L H, ZHANG Y X, et al. Knowledge-enhanced top-k recommendation in poincaré ball[C]// *Proceedings of the 35th AAAI Conference on Artificial Intelligence*, AAAI 2021, 33rd Conference on Innovative Applications of Artificial Intelligence, IAAI 2021, The 11th Symposium on Educational Advances in Artificial Intelligence, EAAI 2021, Virtual Event, February 2-9, 2021: 4285-4293.
- [42] NICKEL M, KIELA D. Poincaré embeddings for learning hierarchical representations[C]//*Proceedings of the 31st Annual Conference on Neural Information Processing Systems*, Long Beach, CA, USA, December 4-9, 2017: 6338-6347.
- [43] CAO Y X, WANG X, HE X N, et al. Unifying knowledge graph learning and recommendation: Towards a Better Understanding of User Preferences[C]//*Proceedings of the 28th International World Wide WebConference*, San Francisco, May 13-17, 2019. New York:ACM, 2019: 151-161.
- [44] MA W Z, ZHANG M, CAO Y, et al. Jointly learning explainable rules for recommendation with knowledge graph[C]//*Proceedings of the 2019 World Wide Web Conference*, San Francisco, CA, USA, May 13-17, 2019: 1210-1221.
- [45] PALUMBO E, MONTI D, RIZZO G, et al. Entity2rec: property-specific knowledge graph embeddings for item recommendation[J]. *Expert Systems with Applications*, 2020, 151: 113235
- [46] GROVER A, LESKOVEC J. Node2vec: scalable feature learning for networks[C]//*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, San Francisco, CA, USA, August 13-17, 2016: 855-864.
- [47] WANG H W, ZHANG F Z, WANG J L, et al. RippleNet: Propagating user preferences on the knowledge graph for recommender systems[C]//*Proceedings of the 27th ACM International Conference on Information and Knowledge Management*, Torino, Italy, October 22-26, 2018: 417-426.
- [48] LIN Y, XU B, FENG J J, et al. Knowledge-enhanced recommendation using item embedding and path attention[J]. *Knowledge-Based Systems*, 2021. 233: 107484.
- [49] WANG X, WANG D X, XU C R, et al. Explainable reasoning over knowledge graphs for recommendation [C]//*Proceedings of the the 33rd AAAI Conference on Artificial Intelligence*, AAAI 2019, The 31st Innovative Applications of Artificial Intelligence Conference, IAAI 2019, The 9th AAAI Symposium on Educational Advances in Artificial Intelligence, EAAI 2019, Honolulu, Hawaii, USA, January 27-February 1, 2019: 5329-5336.
- [50] FU Z H, XIAN Y K, GAO R Y, et al. Fairness-aware explainable recommendation over knowledge graphs[C]// *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, Virtual Event, China, July 25-30, 2020: 69-78.
- [51] WANG X, XU Y K, HE X N, et al. Reinforced negative sampling over knowledge graph for recommendation[C]// *Proceedings of the 2020 WorldWide Web Conference*, Taipei, Taiwan, April 20-24, 2020: 99-109.
- [52] ZHAO K Z, WANG X T, ZHANG Y R, et al. Leveraging demonstrations for reinforcement recommendation reasoning over knowledge graphs[C]//*Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, Virtual Event, China, July 25-30, 2020: 239-248.
- [53] TAO S H, QIU R H, PING Y, et al. Multi-modal knowledge-aware reinforcement learning network for explainable recommendation[J]. *Knowledge-Based Systems*, 2021. 227: 107217.
- [54] LIU D Y, LIAN J X, LIU Z, et al. Reinforced anchor knowledge graph generation for news recommendation reasoning[C]//*Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, Virtual Event, Singapore, August 14-18, 2021. ACM 2021: 1055-1065.
- [55] YANG Z X, DONG S B. HAGERec: Hierarchical atten-



- tion graph convolutional network incorporating knowledge graph for explainable recommendation[J]. Knowledge-Based Systems, 2020. 204: 106194
- [56] LIU N H, GE Y, LI L, et al. Explainable recommender systems via resolving learning representations[C]// Proceedings of the 29th ACM International Conference on Information and Knowledge Management, Virtual Event, Ireland, October 19-23, 2020: 895-904.
- [57] CAO X S, SHI Y L, YU H, et al. DEKR: Description enhanced knowledge graph for machine learning method recommendation[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval, Virtual Event, Canada, July 11-15, 2021: 203-212.
- [58] LIN X, QUAN Z, WANG Z J, et al. KGNN: Knowledge graph neural network for drug-drug interaction prediction [C]//Proceedings of the 29th International Joint Conference on Artificial Intelligence, Yokohama, Japan, 2020: 2739-2745.
- [59] ZHANG L S, KANG Z, SUN X X, et al. KCRec: Knowledge-aware representation graph convolutional network for recommendation[J]. Knowledge-Based Systems, 2021. 230: 107399.
- [60] XIA L H, HUANG C, XU Y, et al. Knowledge-enhanced hierarchical graph transformer network for multi-behavior recommendation[C]//Proceedings of the 35th AAAI Conference on Artificial Intelligence, AAAI 2021, 33rd Conference on Innovative Applications of Artificial Intelligence, IAAI 2021, The 11th Symposium on Educational Advances in Artificial Intelligence, EAAI 2021, Virtual Event, February 2-9, 2021: 4486-4493
- [61] TAI C Y, HUANG L Y, HUANG C K, et al. User-centric path reasoning towards explainable recommendation[C]// Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval, Virtual Event, Canada, July 11-15, 2021: 879-889.
- [62] JIA Z Y, WU M D, YANG H, et al. Temporal sensitive heterogeneous graph neural network for news recommendation[J]. Future Generation Computer Systems, 2021. 125: 324-333.
- [63] WANG X, HE X N, CAO Y X, et al. KGAT: Knowledge graph attention network for recommendation[C]// Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, Anchorage, AK, USA, August 4-8, 2019: 950-958.
- [64] WANG X, HUANG T L, WANG D X, et al. Learning intents behind interactions with knowledge graph for recommendation[C]//Proceedings of the 2021 World Wide Web Conference, Virtual Event/Ljubljana, Slovenia, April 19-23, 2021: 878-887.
- [65] CAO Z Y, QIAO X H, JIANG S, et al. An efficient knowledge-graph-based web service recommendation algorithm[J]. Symmetry-Basel, 2019. 11(3): 392.
- [66] MENG W J, YANG D Q, XIAO Y H. Incorporating user micro-behaviors and item knowledge into multi-task learning for session-based recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, Virtual Event, China, July 25-30, 2020: 1091-1100.
- [67] LI Y J, TARLOW D, BROCKSCHMIDT M, et al. Gated graph sequence neural networks[C]//Proceedings of the 4th International Conference on Learning Representations, San Juan, Puerto Rico, May 2-4, 2016.
- [68] TANG X L, WANG T Y, YANG H Z, et al. AKUPM: Attention-enhanced knowledge-aware user preference model for recommendation[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, Anchorage, AK, USA, August 4-8, 2019: 1891-1899.
- [69] ZHOU Z L, LIU S W, XU G D, et al. Knowledge-based recommendation with hierarchical collaborative embedding[C]//Proceedings of the 22nd Pacific-Asia Conference on Advances in Knowledge Discovery and Data Mining Melbourne, VIC, Australia, June 3-6, 2018: 222-234.
- [70] HE M, WANG B, DU X K. HI2Rec: Exploring knowledge in heterogeneous information for movie recommendation[J]. IEEE Access, 2019. 7: 30276-30284.
- [71] ZHANG M W, ZHAO J W, DONG H, et al. A knowledge graph based approach for mobile application recommendation[C]//Proceedings of the 18th International Conference on Service-Oriented Computing, Dubai, United Arab Emirates, December 14-17, 2020: 355-369.
- [72] WANG H W, ZHANG F Z, ZHAO M, et al. Multi-task feature learning for knowledge graph enhanced recommendation [C]//Proceedings of the 2019 World Wide Web Conference, San Francisco, May 13-17, 2019. New York:ACM, 2019: 2000-2010.
- [73] SHI C, HU B B, ZHAO W X, et al. Heterogeneous information network embedding for recommendation[J]. IEEE Transactions on Knowledge and Data Engineering,

2019. 31(2): 357-370.
- [74] HE Y F, ZHANG Y W, QI L Y, et al. Outer product enhanced heterogeneous information network embedding for recommendation[J]. *Expert Systems with Applications*, 2021, 169: 114359.
- [75] YAN S R, WANG H S, LI Y X, et al. Attention-aware metapath-based network embedding for HIN based recommendation[J]. *Expert Systems with Applications*, 2021, 174: 114601.
- [76] WANG Y F, TANG S Y, LEI Y T, et al. DisenHAN: Disentangled heterogeneous graph attention network for recommendation[C]//*Proceedings of the 29th ACM International Conference on Information and Knowledge Management*, Virtual Event, Ireland, October 19-23, 2020: 1605-1614.
- [77] WANG R R, MA X, JIANG C, et al. Heterogeneous information network-based music recommendation system in mobile networks[J]. *Computer Communications*, 2020. 150: 429-437.
- [78] GONG F, WANG M, WANG H F, et al. SMR: Medical knowledge graph embedding for safe medicine recommendation[J]. *Big Data Research*, 2021, 23: 100174.
- [79] JOHNSON A E W, POLLARD T J, SHEN L, et al. MIMIC-III, a freely accessible critical care database[J]. *Scientific Data*, 2016. 3.
- [80] SCHRIML L M, ARZE C, NADENDLA S, et al. Disease ontology: a backbone for disease semantic integration[J]. *Nucleic Acids Research*, 2012. 40(D1): D940-D946.
- [81] LAW V, KNOX C, DJOUMBOU Y, et al. Drugbank 4.0: shedding new light on drug metabolism[J]. *Nucleic Acids Research*, 2014. 42(D1): D1091-D1097.
- [82] WANG H F, WANG Z J, HU S H, et al. DUSKG: A fine-grained knowledge graph for effective personalized service recommendation[J]. *Future Generation Computer Systems-the International Journal of Escience*, 2019. 100: 600-617.
- [83] WANG H W, ZHAO M, XIE X, et al. Knowledge graph convolutional networks for recommender systems[C]//*Proceedings of the 2019 World Wide Web Conference*, San Francisco, May 13-17, 2019. New York:ACM, 2019: 3307-3313.
- [84] ZHOU S J, DAI X Y, CHEN H K, et al. Interactive recommender system via knowledge graph-enhanced reinforcement learning[C]//*Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, Virtual Event, China, July 25-30, 2020: 179-188.
- [85] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. *Nature*, 2015. 518(7540): 529-533.
- [86] ZHAO M Y, HUANG X W, ZHU L X, et al. Knowledge graph-enhanced sampling for conversational recommender system[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2021.
- [87] ZHOU KUN, ZHAO W X, BIAN S Q, et al. Improving conversational recommender systems via knowledge graph based semantic fusion[C]//*Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, Virtual Event, CA, USA, August 23-27, 2020: 1006-1014.
- [88] TAI C Y, WU M R, CHU Y W, et al. MVIN: learning multiview items for recommendation[C]//*Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, Virtual Event, China, July 25-30, 2020: 99-108.
- [89] ZHAO J, ZHOU Z, GUAN Z Y, et al. IntentGC: A scalable graph convolution framework fusing heterogeneous information for recommendation[C]//*Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, Anchorage, AK, USA, August 4-8, 2019: 2347-2357.
- [90] LEI S, XU M, QIAN S S, WU S D. Knowledge graph enhanced neural collaborative recommendation[J]. *Expert Systems with Applications*, 2021. 164: 113992.
- [91] TU K, CUI P, WANG D X, et al. Conditional Graph Attention Networks for Distilling and Refining Knowledge Graphs in Recommendation[C]//*Proceedings of the 30th ACM International Conference on Information and Knowledge Management*, Virtual Event, Queensland, Australia, November 1-5, 2021: 1834-1843.
- [92] CHEN C, ZHANG M, MA W Z, et al. Jointly non-sampling learning for knowledge graph enhanced recommendation[C]//*Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, Virtual Event, China, July 25-30, 2020: 189-198.
- [93] ZHANG Z Y, ZHANG L, YANG D Q, et al. KRAN: Knowledge refining attention network for recommendation[J]. *ACM Transactions on Knowledge Discovery from Data*, 2021. 16(2): Article 39.
- [94] WANG Z, LIN G Y, TAN H B, et al. CKAN: Collabora-

- tive knowledge-aware attentive network for recommender systems[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, Virtual Event, China, July 25-30, 2020: 219-228.
- [95] SUN R, CAO X Z, ZHAO Y, et al. Multi-modal knowledge graphs for recommender systems[C]// Proceedings of the 29th ACM International Conference on Information and Knowledge Management, Virtual Event, Ireland, October 19-23, 2020: 1405-1414.
- [96] LEE D, OH B, SEO S, et al. News recommendation with topic-enriched knowledge graphs[C]//Proceedings of the 29th ACM International Conference on Information and Knowledge Management, Virtual Event, Ireland, October 19-23, 2020: 695-704.
- [97] WANG H W, ZHANG F Z, ZHANG M D, et al. Knowledge-aware graph neural networks with label smoothness regularization for recommender systems[C]// Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, Anchorage, AK, USA, August 4-8, 2019: 968-977.
- [98] TOGASHI R, OTANI M, SATOH S. Alleviating cold-start problems in recommendation through pseudo-labelling over knowledge graph[C]//Proceedings of the 14th ACM International Conference on Web Search and Data Mining, Virtual Event, Israel, March 8-12, 2021: 931-939.
- [99] LONG X L, HUANG C, XU Y, et al. Social recommendation with self-supervised metagraph informax network[C]//Proceedings of the 30th ACM International Conference on Information and Knowledge Management, Virtual Event, Queensland, Australia, November 1-5, 2021: 1160-1169.
- [100] MILLER A H, FISCH ADAM, DODGE J, et al. Key-value memory networks for directly reading documents[C]//Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, Austin, Texas, USA, November 1-4, 2016: 1400-1409.
- [101] WANG B, CAI W. Knowledge-enhanced graph neural networks for sequential recommendation[J]. Information, 2020. 11(8): 388.
- [102] WANG C Y, ZHANG M, NA W Z, et al. Make it a chorus: knowledge and time-aware item modeling for sequential recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, Virtual Event, China, July 25-30, 2020: 109-118.
- [103] LIU Y, LI B H, ZANG Y L, et al. A knowledge-aware recommender with attention-enhanced dynamic convolutional network[C]//Proceedings of the 30th ACM International Conference on Information and Knowledge Management, Virtual Event, Queensland, Australia, November 1-5, 2021: 1079-1088.
- [104] WANG P F, FAN Y, XIA L, et al. KERL: A knowledge-guided reinforcement learning model for sequential recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, Virtual Event, China, July 25-30, 2020: 209-218.
- [105] CHOWDHURY G, SRILAKSHMI M, CHAIN M, et al. Neural factorization for offer recommendation using knowledge graph embeddings[C]//Proceedings of the SIGIR 2019 Workshop on eCommerce, co-located with the 42st International ACM SIGIR Conference on Research and Development in Information Retrieval, Paris, France, July 25, 2019.
- [106] HE X N, CHUA T S. Neural factorization machines for sparse predictive analytics[C]//Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval, Shinjuku, Tokyo, Japan, August 7-11, 2017: 355-364.
- [107] WANG T, SHI D Q, WANG Z D, et al. MRP2Rec: exploring multiple-step relation path semantics for knowledge graph-based recommendations[J]. IEEE Access, 2020. 8: 134817-134825.
- [108] RUDER S. An Overview of Multi-Task Learning in Deep Neural Networks[J]. CoRR, 2017. abs/1706.05098.
- [109] XIONG X, QIAO S J, HAN N, et al. Where to go: An effective point-of-interest recommendation framework for heterogeneous social networks[J]. Neurocomputing, 2020. 373: 56-69.
- [110] SALAKHUTDINOV R R, MNH A. Bayesian probabilistic matrix factorization using markov chain monte carlo[C]//Proceedings of the 25th ACM International Conference on Machine Learning, Helsinki, Finland, June 5-9, 2008: 880-887.
- [111] WANG H W, ZHANG F Z, XIE X, et al. DKN: Deep knowledge-aware network for news recommendation[C]// Proceedings of the 2018 World Wide Web Conference on World Wide Web, Lyon, France, April 23-27, 2018: 1835-1844.
- [112] QI T, WU F Z, WU C H, et al. Personalized news recommendation with knowledge-aware interactive match-

ing[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval, Virtual Event, Canada, July 11-15, 2021: 61-70.

- [113] KIM Y. Convolutional neural networks for sentence classification[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, A meeting of SIGDAT, a Special Interest Group of the ACL. October 25-29, 2014, Doha, Qatar, 2014: 1746-1751.

- [114] WU Z H, PAN S R, CHEN F W, et al. A comprehensive survey on graph neural networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021. 32(1): 4-24.

- [115] LIU J W, SHI C, YANG C, et al. Review of recommendation system based on heterogeneous information network[J]. Journal of Information Security, 2021, 6(05): 1-16.

刘佳玮, 石川, 杨成, 菲利普 俞. 基于异质信息网络的推荐系统研究综述[J]. 信息安全学报, 2021, 6(05): 1-16.

- [116] XIA F, SUN K, YU S, et al. Graph learning: A survey[J]. IEEE Transactions on Artificial Intelligence. 2021. 2(2): 109-127.

- [117] TU C C, YANG C, LIU Z Y, et al. Network representation learning: an overview (in Chinese)[J]. Sci Sin Inform, 2017, doi: 10.1360/N112017-00145

涂存超, 杨成, 刘知远, 等. 网络表示学习综述[J]. 中国科学: 信息科学, 2017, doi: 10.1360/N112017-00145



**陈杭雪** (1997—), 女, 浙江衢州人, 硕士研究生, 主要研究方向为智能信息处理、个性化推荐等。

**CHEN Hangxue**, born in 1997, M.S. candidate. Her research interests include intelligent information processing, personalized recommendation, etc.



**田萱** (1976—), 女, 山东济宁人, 博士, 副教授, 主要研究方向为智能信息处理、文本挖掘等。

**TIAN Xuan**, born in 1976, Ph.D., associate professor. Her research interests include intelligent information processing, text mining, etc.